NAPROUS

Clément

Licence Professionnelle

Métiers du Décisionnel et de la Statistique

RAPPORT D'ALTERNANCE

Du 24 octobre 2022 au 1 septembre 2023

AU SEIN DE L'UNIVERSITE DE PAU ET DES PAYS DE L'ADOUR

DPAC : Direction Pilotage et Amélioration Continue / Observatoire de l'Etablissement - Volet Recherche

TUTRICE ALTERNANCE : Marielle [redacted]

TUTEUR FORMATION : Mohamed [redacted]

SOMMAIRE

REMERCIEMENTS 1
SOURCES UTILISEES POUR L'INTRODUCTION 1
I. INTRODUCTION 2
I.1. Contexte de l'alternance 2
I.2.1. Présentation de l'UPPA 3
I.2.2. Quelques chiffres 3
I.2.3. Les objectifs de l'UPPA 3
I.2.3.1. La recherche 3
I.2.3.2. Partenariat et innovations 4
I.2.3.3. International 5
I.3. Les missions 6
II. Méthodologie 7
II. 1. Contexte de la première partie d'alternance 7
II. 2. Présentation du Système d'information « recherche » utilisé à l'UPPA 7
II. 2.1. Cocktail 7
II. 2.2. Sangria 7
II. 2.3. Agrhum 8
III. Travail effectué 10
III. 1. Les partenaires de la recherche 10
III. 1. 2. Compléments partenaires 13
III. 2. Le financement des doctorants 16
III. 3. Les publications des chercheurs de l'UPPA 18
III. 4. Visualisation de données 21
IV. Bilan de cette première partie d'alternance 23
V. Seconde partie d'alternance 24
V. 1.1. Retour sur le référentiel HAL 24
V. 1.2. La bibliométrie et ses objectifs 25
V. 1.3. Exploitation des dépôts HAL 26
V. 1.4. Qualification des individus de l'UPPA 27
V. 1.5. Caractéristiques des produisant 34
V. 2. Changement de méthode 37
VI. Conclusion 41

REMERCIEMENTS

Je tiens à remercier toutes les personnes qui ont contribué au bon déroulement de cette alternance et qui m'ont aidé lors de la rédaction de ce rapport.

Tout d'abord, je tiens à remercier Marielle [redacted] ma tutrice d'alternance pour son soutien, le temps qu'elle m'a consacré et le partage de son expérience. Elle m'a aussi beaucoup assisté pour la réalisation des premiers projets par la proposition de différentes méthodes. Je remercie également l'ensemble des collègues au sein du pôle de la DRV pour leur accueil et qui ont permis mon intégration dans les meilleures conditions possibles.

Enfin, je remercie les personnes qui m'ont aidé à la relecture et à la rédaction de ce rapport d'alternance.

SOURCES UTILISEES POUR L'INTRODUCTION

https://intranet.univ-pau.fr/fr/notre-universite/poles/pole-vie-institutionnelle-et-appui-au-pilotage.html

https://intranet.univ-pau.fr/fr/notre-universite/organigramme.html

Emergence - Rapport d'activité-2022-web

I. INTRODUCTION

I.1. Contexte de l'alternance

Mon alternance se déroule au sein de la Direction Pilotage et Amélioration Continue (DPAC), un des services qui composent l'Observatoire De l'Etablissement (ODE) de l'université de Pau et des Pays de l'Adour. L'ODE est engagé dans plusieurs domaines, tels que : la production de données et d'indicateurs de pilotage sur les étudiants et les formations, mais également la conception et réalisation d'enquêtes et outils de collecte et traitements des données. Les missions qui me concernent sont exclusivement sur le volet de la recherche, de ce fait je suis localisé au plus près de la direction Métier : Direction de la Recherche et de la Valorisation (DRV).

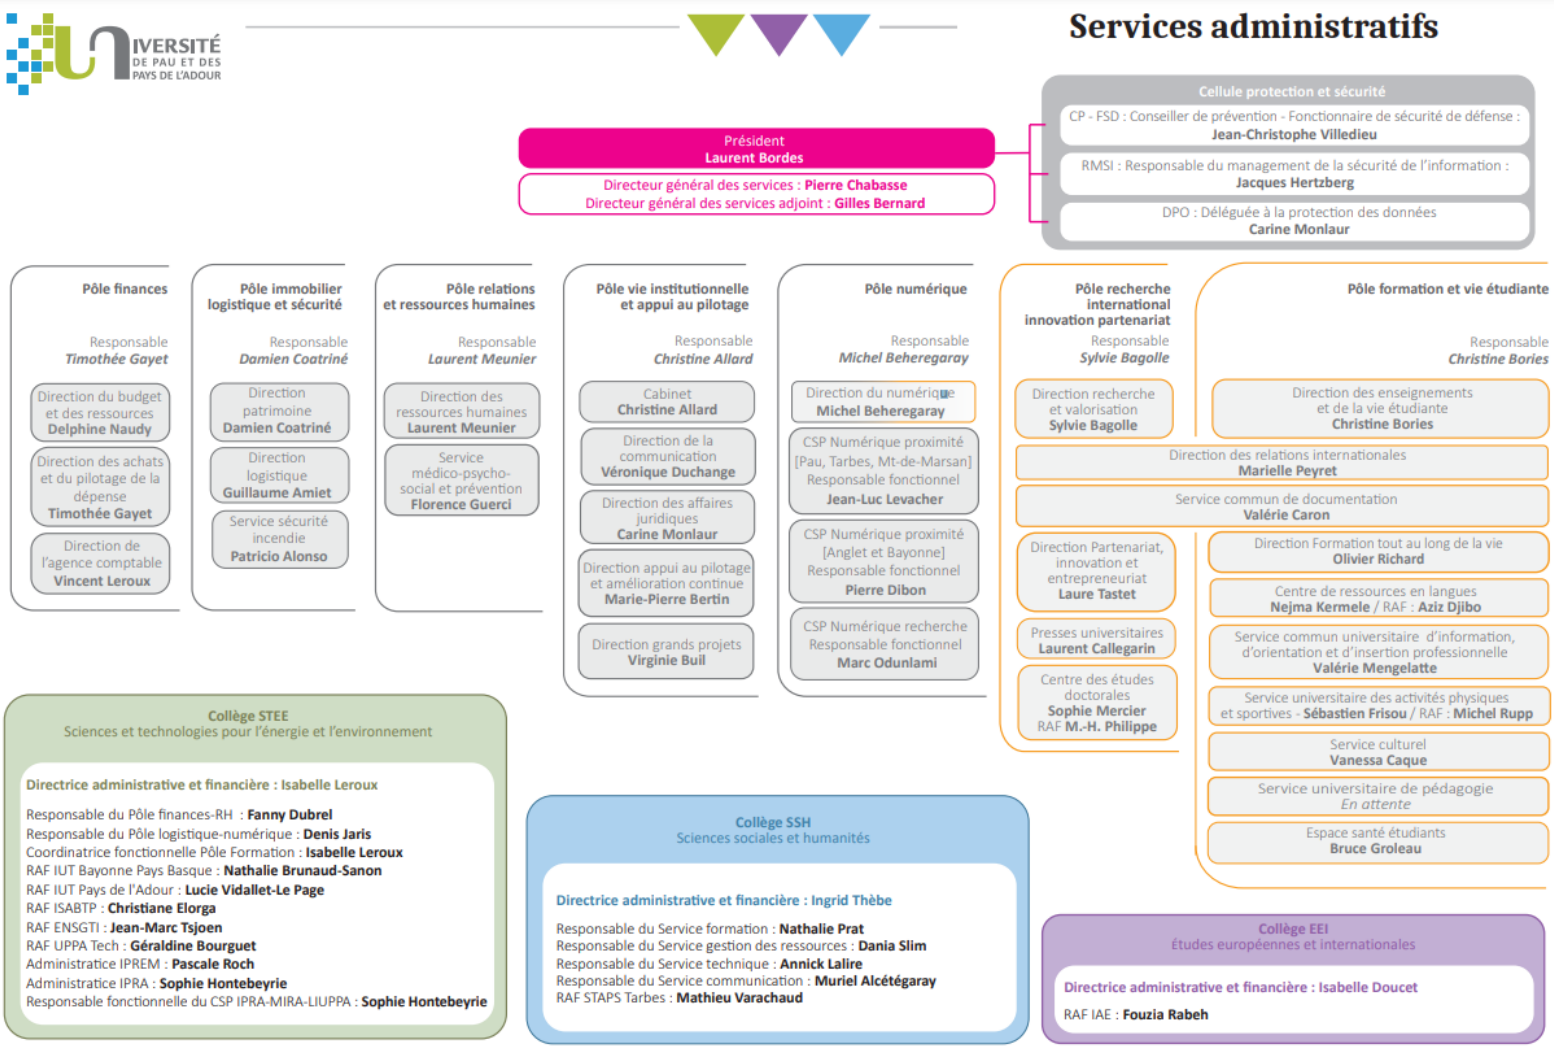

Organigramme services administratif de l'UPPA

I.2.1. Présentation de l'UPPA

L'UPPA est un établissement supérieur français fondé en 1970. Elle est basée dans le bassin et les Pays de l'Adour ; à Pau mais aussi à Bayonne et Anglet dans les Pyrénées Atlantiques, à Tarbes dans les Hautes-Pyrénées et à Mont-de-Marsan dans les Landes. Elle dépend de l'académie de Bordeaux.

I.2.2. Quelques chiffres

En 2022 elle comptait 1699 personnels, 13841 étudiants se préparant à l'obtention de près de 120 diplômes, en formations initiales, professionnelles, continues, ou en alternance. Chaque année, elle accueille plus de 1900 étudiants étrangers. En effet elle est impliquée dans 129 accords de coopération inter-universitaire et 193 universités partenaires Erasmus. Elle participe à des échanges d'étudiants, d'enseignants et de chercheurs au niveau international. De par sa situation géographique avec l'Espagne, l'UPPA développe des coopérations universitaires avec l'Université de Saragosse, l'Université du Pays basque et l'Université de Navarre, aussi bien dans le domaine de l'enseignement que de la recherche.

Labélisée *investissement d'avenir,* l'Université de Pau est reconnue par le gouvernement français comme « université d'excellence » avec :

- Le label I-SITE avec le projet E2S (Solutions pour l'Energie et l'Environnement), porté par le consortium UPPA, INRAE, INRIA, CNRS, en 2017
- Le label Nouveau Cursus à l'Université (NCU) avec le projet Spécialisation Progressive et Accompagnée des Cursus Etudiants (SPACE), en 2018

I.2.3. Les objectifs de l'UPPA

I.2.3.1. La recherche

Parmi les missions de l'UPPA, on retrouve un premier axe, le volet recherche. Il a pour but de :

*Renforcer la visibilité des unités de recherche

- 19 unités de recherche
- 5 fédérations de recherche
- 1 Equipex en réseau
- 5 laboratoires internationaux
- 3 réseaux européens de recherche et innovations
- 33 591 références dans l'archive ouverte HAL

- 2 578 publications répertoriées

*Former à et par la recherche pour développer des compétences transversales

- 1 école universitaire de recherche
- 5 programmes doctoraux européens
- 107 docteurs

*Donner à chaque enseignant-chercheur ou chercheur, les moyens de mener à bien ses activités de recherches

- 20 plateaux techniques
- 3 bibliothèques spécialisées
- 18,1 M euros de ressources propres
- 1 446 personnels dans les laboratoires
- 30 chaires

*Favoriser l'émergence d'une identité scientifique partagée

- Une identité scientifique tournée vers les défis sociétaux :
    - Organiser la subsidiarité énergétique à l'échelle des territoires
    - Concilier développement, environnement sécurisé et biodiversité préservée
    - Adapter les écosystèmes littoraux, forêt et montagnes pour les rendre plus résilient
- Un label Science avec et pour la société (SAPS)

*Consolider le pilotage

- 1 feuille de route recherche
- 2 conventions cadres
- 1 contrat objectifs moyens

I.2.3.2. Partenariat et innovations

Ce deuxième axe a pour vocation de :

*Renforcer le rôle de l'UPPA comme acteur essentiel du développement économique et culturel du territoire

- UPPA Tech
    - 1,7 M d'euros de chiffre d'affaires
    - 47 prestations
    - 11 partenaires issus des ressources générées
- 40 partenaires CEPyA – Club entreprises de l'UPPA
- 2 accords-cadres signés dans l'année
- Relations avec les partenaires institutionnels
- 248 contrats de recherche partenariaux
    - 6,5 M d'euros de chiffre d'affaires dont 2,1 M de l'institut Carnot ISIFoR

    - 13 partenaires liés aux laboratoires communs
    - 2 partenaires liés aux hubs partenariaux

*Libérer et réussir la convergence publique privé l'esprit d'innovation et d'entrepreneuriat

- 116 brevets
- Un réseau Alumni
    - 35 000 membres diplômés
    - 70 créateurs d'entreprise
- Entreprenariat
    - 107 étudiants entrepreneurs
    - 5 créations d'entreprises/Start-ups étudiantes
    - 7 doctorants entrepreuneurs
- UNITA

*Accompagner les acteurs de la recherche et de la formation pour intensifier les partenariats en lien avec les 5 missions interdisciplinaires

- 1,3 M d'euros enveloppe du ressourcement de l'institut Carnot ISIFoR
- 2 journées innovation laboratoire
- 6 évènements avec le CEPyA
    - 2 conférences et webinaires
    - 2 évènements mettant en avant les adhérents
    - 1 assemblée générale

I.2.3.3. International

Enfin comme dernier axe on retrouve un modèle d'internationalisation progressive qui a pour but :

*Etablir et renforcer les partenariats

- 12 établissements partenaires
    - 5 partenaires E2S UPPA
    - 3 partenaires transfrontaliers
    - 5 partenaires UNITA

*Accroître, diversifier et formaliser la mobilité

- Mobilité Erasmus
    - 97 étudiants entrants
    - 228 étudiants sortants
    - 28 personnels sortants
- 2 156 étudiants de nationalité étrangère
- 19 parcours de master 100% en anglais

*Digitaliser les services de relations internationales

- 1 hub international déployé 2022

- 3 processus de candidature en ligne
- 1% de digitalisation des accords inter-institutionnels Erasmus

*Accroître et renforcer la visibilité et l'attractivité à l'international

- Classement international de Shangai
    - Rang 301-400 Champs thématique Sciences et ingénierie de l'énergie
- Classement du Times Higher Education
    - Au-delà de rang 1200
    - Rang 326 – Classement général pour l'international
    - Rang 601-800 Classement thématique pour les sciences de la vie
    - Rang 601-800 Classement thématique pour l'ingénierie
    - Rang 801-1000 Classement thématique pour les sciences physiques

I.3. Les missions

L'ODE est engagé dans plusieurs domaines, tels que : la production de données et d'indicateurs de pilotage sur les étudiants et les formations, mais également la conception et réalisation d'enquêtes et outils de collecte et traitements des données. Les missions qui me concernent sont exclusivement sur le volet de la recherche, de ce fait je suis localisé au plus près de la direction Métier : Direction de la Recherche et de la Valorisation (DRV).

Les différents cœurs de métier formation / recherche … ont des besoins à des fins statistiques / articulation direction pilotage

Le rôle qui m'a été attribué consistait à accompagner la mise en place d'outils de pilotage passant par la vérification de la qualité du SI et ses corrections, l'accompagnement à l'exploitation de données statistiques, la visualisation …

Me concernant, mes tâches comprenaient :

Contribuer au contrôle qualité des données extraites du système d'informations de l'UPPA

- Contrôle de valeurs manquantes
- Test de cohérence des données
- Test des requêtes du SI

Développer un référentiel de données pour caractériser les partenaires de la recherche

- Mobilisation des données nationales (import des données INSEE, localisation des partenaires à partir des numéro SIRET)
- Jointure avec SI interne

Traitements statistiques :

- datavisualisation

II. Méthodologie

II. 1. Contexte de la première partie d'alternance

La première partie de mon alternance concernait surtout la fiabilisation des données au sein du système informatique de l'université de Pau. Le Pôle recherche international innovation partenariat dans lequel on retrouve la direction métier de la DRV a pour but de fournir un certain nombre de travaux à des fins statistiques. Parmi ses missions, on retrouve :

- La coordination et la mise en œuvre de la politique de recherche et d'innovation de l'Etablissement en lien avec les tutelles partenaires des structures de recherche
- Le pilotage administratif de la recherche et la mise en place d'outils et d'indicateurs d'aide au pilotage et à la décision

Mon travail consistait majoritairement à vérifier la cohérence des données dans différents référentiels. Je n'ai pas travaillé directement en dur sur la base de données mais plutôt sur des exports de logiciels de la suite Cocktail.

II. 2. Présentation du Système d'information « recherche » utilisé à l'UPPA

II. 2.1. Cocktail

Cocktail propose une suite de logiciels modulaires et interopérables permettant aux universités et grandes écoles de gérer et piloter les finances, la comptabilité, les ressources humaines et la paye, la scolarité et la recherche. Les objectifs principaux de Cocktail sont les suivants :

- Permettre l'échange, la mutualisation et le co-développement sont des fondements du fonctionnement de la structure.

- Animer et professionnaliser des méthodes de co-construction et faire de l'Association une véritable plateforme de construction collaborative d'un SI pour le monde de l'ESR (Enseignement Supérieur Recherche), tout en restant lié aux établissements et partenaires de l'Enseignement Supérieur.

II. 2.2. Sangria

Sangria est l'un des environnements dont provenait les données que j'exploitais. Il se place dans le domaine de la recherche. Cette solution est utilisée à la fois par les directions de la Recherche des établissements, les unités de recherche et les laboratoires, elle permet de

gérer les structures et les personnels de recherche, les contrats de recherche, les dossiers de financement et de générer les indicateurs de pilotage de la Recherche.

Ses fonctionnalités sont les suivantes :

Gérer les structures

- Intégrer les unités de recherche, fédérations de recherche, écoles doctorales, …
- Récupérer les personnels gérés en RH pour les affecter dans les équipes et définir leur rôle au sein d'un laboratoire
- Gérer les dotations financières en synchronisant avec la sphère GFC (finance et comptabilité)
- Gérer et historiser des évaluations stratégiques des structures, des équipes de recherche et des programmes

Gérer les Projets

- Gérer les réponses aux appels d'offres et les historiser
- Gérer les partenaires, les conventions et les contrats de recherche

II. 2.3. Agrhum

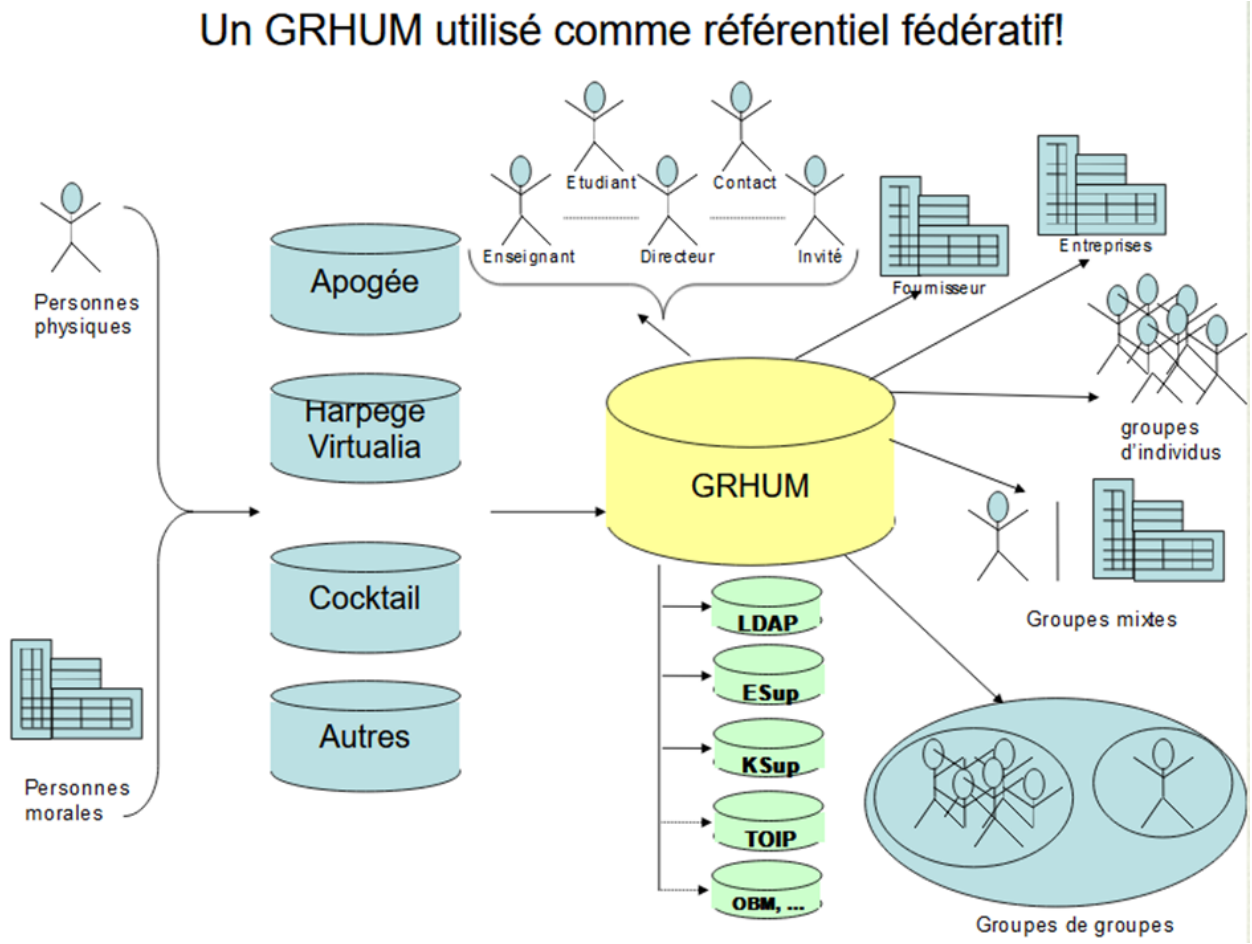

Agrhum est le référentiel sur lequel s'appuie toutes les briques du SI interne de l'UPPA. Par exemple il fédère la partie gestion des dossiers d'inscription des étudiants (APOGEE), la partie RH (Harpege Virtualia) …

Organisation des individus

- Centraliser les individus en formation
- Centraliser les employés
- Centraliser les hébergés
- Centraliser les fournisseurs et clients physiques
- Centraliser les contacts physiques

Organisation des structures

- Centraliser les groupes
- Centraliser les partenaires, les entreprises
- Centraliser les établissements publics
- Centraliser les autres personnes morales

Reporter

- Lister les individus ou les structures

III. Travail effectué

III. 1. Les partenaires de la recherche

CONTEXTE

Les partenaires de la recherche sont un indicateur important pour l'université, un référentiel recensant ces données est nécessaire pour les exploiter.

OBJECTIF

Mon premier travail a été de qualifier les partenaires de la recherche de l'UPPA. Les données permettant ce travail proviennent d'exports de Sangria. J'ai procédé de la façon suivante.

A partir de tables portant sur les contrats et les subventions, le but est d'obtenir une table finale sans doublons où l'on retrouve pour un individu le nombre de contrats et subventions dans lequel il est impliqué.

METHODOLOGIE

Les partenaires de l'UPPA sont impliqués dans des contrats et/ou subventions. Le fichier Excel se compose de façon suivante : 2 onglets concernant les contrats et subventions. L'un correspond à la synthèse des contrats, on y retrouve parmi les informations utiles :

- Un numéro de contrat / subvention
- Le nom du partenaire associé
- Une année de signature
- Un statut administratif (diffusé, abandonné, négociation...)

Le second onglet correspond au détail des partenaires associés. On y retrouve :

- Le nom du partenaire
- Un code fournisseur
- Un PersId
- Un numéro de contrat / subvention

	A	B	C	I	J	L	X
1	Numéro	Titre du contrat	Acronyme	Laboratoires	Laboratoire principal	Partenaires	Année de signatur
2	CONT-2009-0159	Sûreté nucléaire et protection de l'homme et de	l'environnement contre les effets négatifs de	IPREM UMR 5254	IPREM UMR 5254	IRSN (INSTITUT DE RADIOPROTECTION ET DE SURETE NUCLEAIRE)	2009
3	CONT-2009-0160	Accord-cadre UPPA / NOBATEK	accord cadre NOBATEK	SIAME EA 4581	SIAME EA 4581	NOBATEK/INEF4	2009
4	CONT-2009-0161	XYLOFUTUR - Cap Forest 2009-2011: convention	XYLOFUTUR	IPREM UMR 5254	IPREM UMR 5254	FCBA / BORDEAUX SCIENCES AGRO / ESB / XYLOFUTUR / INRAE PARIS / UNIVERSIT	2009
5	CONT-2009-0162	Recherches sur les ovins lait des Pyrénées-Atlar	GIS ID64 Ovins lait	SET UMR 5603 / LIREM	LIREM	GDS 64 / AREOVLA / SYNDICAT DE DEFENSE DE L'APPELLATION OSSAU-IRATY / LA (	2009
6	CONT-2009-0163	CEOS.fr: comportement et évaluation des ouvrag	CEOS.fr	SIAME EA 4581	SIAME EA 4581	IREX	2009
7	CONT-2009-0164	Accueil Wareerom Polrut au sein de CANBIO: formulate au thermoplastic based nanocomposi		CANOE	CANOE	THAI POLYETHYLENE CO., LTD. / CNRS DR15 / ARKEMA FRA	2009
8	CONT-2009-0165	Accueil Thierry FOUILLET au sein de l'IPREM: analyse des capacités photooxydantes de film P		IPREM UMR 5254	IPREM UMR 5254	ARKEMA FRA / CNRS DR15	2009
9	CONT-2009-0166	Accueil Yosra CHAHBANI au sein de l'IPREM: étude et optimisation d'une filière de haute rési		IPREM UMR 5254	IPREM UMR 5254	ECOLE NATIONALE D'INGENIEURS DE TUNIS / CHAHBANI Yosra	2009
10	CONT-2009-0167	Avenant n°1 accueil Jean-Claude SALVADO au sein d'ECOBIOP: étude génétique des populatic		IPREM UMR 5254	IPREM UMR 5254	INRAE PARIS	2009

Capture des 10 premières lignes de l'onglet 'Contrat (Synthèse)'

	A	B	C	D	J	L	M
1	Nom du partenaire	Code fournisse	PersId du partenaire	Numéro du partenair	Numéro	Acronyme	Suivi administratif
2	2 MORO	2MO00001	159842	49107	CONT-2011-0152	OMNI-DATA	Diffusé
3	2PMO	2PM00001	524079	332378	CONT-2022-0085		Signé Partenaire 1er
4	45-8 GROUP	45800002	514181	329846	CONT-2020-0081	GEODENERGIES_GEFISS E2S_CHAIRE_TEEN Avenant 2	Diffusé
5	45-8 GROUP	45800002	514181	329846	CONT-2021-0375	H2NA_Consortium	Diffusé
6	45-8 GROUP	45800002	514181	329846	CONT-2021-0196	Plan France Relance - 45-8 ENERGY - LFCR	Diffusé
7	45-8 GROUP	45800002	514181	329846	CONT-2022-0109	Plan France Relance - H2 Namibie	Diffusé
8	4D VIRTUALIZ	4DV00001	226803	76218	CONT-2017-0137	FUI TORNADO	Diffusé
9	4D VIRTUALIZ	4DV00001	226803	76218	CONT-2020-0299	TORNADO	Diffusé
10	A-CORROS	COR00138	512203	328852	CONT-2019-0346	SOS Epaves	Diffusé

Capture des 10 premières lignes de l'onglet 'Contrat_Partenaire'

Les onglets 'Subvention (Synthèse)' et 'Subvention_Partenaire' ont la même structure que les onglets respectifs des contrats, seul le **Numéro** change en prenant la forme suivante :

'SUBV-[année]-[num]'

La table de 'Contrat_Partenaire' possède 7 689 entrées et 'Subvention_Partenaire' en a 3426, si on combine ces 2 tables on obtient donc une nouvelle avec 11 116 entrées

	A	B	C	D	E	F
1	PersId du partenaire	Numéro	Nom du partenaire	Code fournisseu	Numéro du partenair	CONT/SUBV
2	159842	CONT-2011-0152	2 MORO	2MO00001	49107	CONT
3	524079	CONT-2022-0085	2PMO	2PM00001	332378	CONT
4	514181	CONT-2020-0081	45-8 GROUP	45800002	329846	CONT
5	514181	CONT-2021-0375	45-8 GROUP	45800002	329846	CONT
6	514181	CONT-2021-0196	45-8 GROUP	45800002	329846	CONT
7	514181	CONT-2022-0109	45-8 GROUP	45800002	329846	CONT
8	226803	CONT-2017-0137	4D VIRTUALIZ	4DV00001	76218	CONT
9	226803	CONT-2020-0299	4D VIRTUALIZ	4DV00001	76218	CONT
10	512203	CONT-2019-0346	A-CORROS	COR00138	328852	CONT

Capture des 10 premières lignes de cette nouvelle table 'Combinaison_Part_Cont_Subv

On rajoute en colonne F une nouvelle variable qui indique si la ligne provient de la table Contrat ou Subvention. La table se divise en 2 blocs de cette façon :

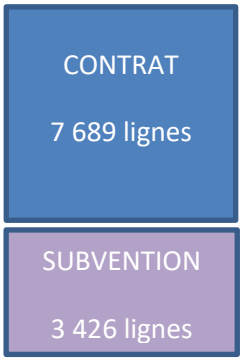

G	H	I	J
Statut	Année signatu	Type partenair	Statut combi
Diffusé	2011	établissement	Diff/Acc
Signé Partenaire 1er	2022	établissement	
Diffusé	2020	établissement	Diff/Acc
Diffusé	2022	établissement	Diff/Acc
Diffusé	2021	établissement	Diff/Acc
Diffusé	2022	établissement	Diff/Acc
Diffusé	2019	établissement	Diff/Acc
Diffusé	2021	établissement	Diff/Acc
Diffusé	2020	établissement	Diff/Acc

On ajoute ensuite des informations supplémentaires, comme le statut et l'année de signature. Ces 2 variables n'étant pas présentes dans les tables '…_Partenaire' on doit effectuer une jointure avec les tables '… (Synthèse)' pour les récupérer.

Récupération de Statut :

=RECHERCHEV(B2;'Contrat (Synthèse)'!A:AD;COLONNE(AB2);FAUX)

On cherche le numéro du contrat en colonne B dans la table 'Contrat (Synthèse)', puis on renvoie le statut en colonne AB de cette table. La manipulation est la même pour l'année.

En colonne I on rajoute aussi une nouvelle variable pour préciser quel est le type de partenaire. La formule est la suivante : **=SI(ET(D2=""; E2= ""); "individu";"établissement")** La colonne D correspond au **Num fournisseur** et E au **Num partenaire**, donc si sur une ligne aucun de ces champs est renseigné il s'agit alors d'une personne physique.

Une fois qu'on a ces informations de la table *'Combinaison_Part_Cont_Subv'* on peut créer un TCD. Dans notre table *'Combinaison_Part_Cont_Subv'* un individu statistique qualifié par un **PersID** peut être relié à plusieurs contrats et/ou subventions. Le TCD permet donc d'obtenir une nouvelle table où 1 ligne = 1 individu statistique et on obtient le nombre de contrats/subventions dans lequel il est impliqué.

Le TCD permet par la suite de combiner son résultat avec la table précédente. On obtient donc une nouvelle table avec les informations qui qualifient le partenaire, le décompte des contrats/subventions avec leurs statut et l'année de signature. L'année de signature correspond à l'année minimale associée à un partenaire, cela permet d'avoir un historique et de savoir depuis combien de temps l'UPPA est en relation avec un partenaire.

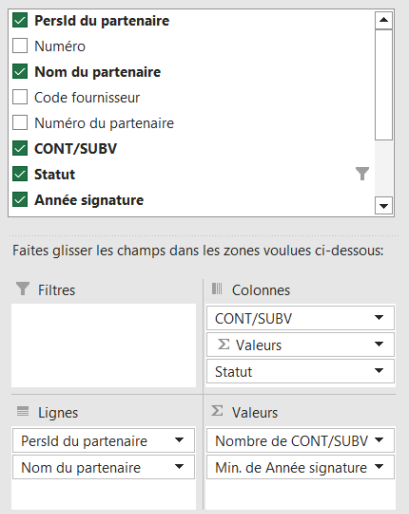

Avec le passage par le TCD pour supprimer les doublons on passe de 11 116 à 2 257 entrées dans notre nouvelle table.

RESULTAT

	A	B	C	D	E	F	G	H	I	J	K
1	PersId du partenaire	Numéro	Nom partenaire	Numéro du partenaire	Code fournisseu	Type partenaire	Statut	Année signature	CONT	SUBV	Total géné
2	110943	CONT-2017-0003	[illegible]	0	(vide)	individu	Diffusé	2017	1		1
3	111177	CONT-2017-0212		0	(vide)	individu	Diffusé	2017	1		1
4	111929	CONT-2009-0228		0	(vide)	individu	Diffusé	2009	1		1
5	112048	CONT-2016-0187		0	(vide)	individu	Diffusé	2017	1		1
6	112744	CONT-2010-0125		0	(vide)	individu	Diffusé	2010	1		1
7	113030	CONT-2010-0110		0	(vide)	individu	Diffusé	2010	1		1
8	113038	CONT-2009-0279		0	(vide)	individu	Diffusé	2009	2		2
9	113324	CONT-2010-0126		0	(vide)	individu	Diffusé	2010	1		1
10	113375	CONT-2009-0216		0	(vide)	individu	Diffusé	2008	1		1
11	114244	CONT-2012-0018		0	(vide)	individu	Diffusé	2012	2		2
12	114564	CONT-2009-0224		0	(vide)	individu	Diffusé	2009	1		1
13	114651	CONT-2011-0063		0	(vide)	individu	Diffusé	2011	5		5
14	114810	CONT-2015-0876		0	(vide)	individu	Diffusé	2016	1		1
15	119067	CONT-2009-0212			ACT00001	établissement	Diffusé	2010	4	2	6

BILAN

Ici une utilisation simple d'Excel était suffisante, mais d'un point de vue relationnel, il fallait être vigilent sur la structure et le lien entre les tables.

III. 1. 2. Compléments partenaires

CONTEXTE

Les partenaires de l'UPPA sont soit des personnes physiques ou morales, et le référentiel doit faire part de cette distinction.

OBJECTIF

Le but du travail est de reprendre la table précédente et d'y rajouter des informations complémentaires, telles que des informations géographiques, et sociales si l'individu est une entreprise.

METHODOLOGIE

A partir de la dernière table *'Combinaison_Part_Cont_Subv',* nous pouvons créer une nouvelle table dans laquelle on rajoute de nouvelles informations, toujours dans le but d'obtenir le plus d'informations possible sur les partenaires.

➔ Création d'une nouvelle table '*Cont_Subv_geo_ent*

Cette table ajoute 2 nouveaux blocs d'informations :

- Des informations géographiques
- Informations sociales concernant les entreprises

Premier bloc rajoute les nouvelles variables :

- Adr_adresse1 (adresse)
- Adr_adresse2 (complément d'adresse)
- Code_postal
- Ville
- C_pays (code pays)
- Ll_pays

Le deuxième bloc rajoute :

- Siret
- Siren
- Statut partenaire
- C_type_structure

Toutes ces nouvelles variables peuvent être ajoutées en effectuant une jointure avec une table temporaire issue d'une extraction sur Agrhum. La méthode est la même que précédemment, via l'utilisation d'une **RECHERCHEV.**

O	P	Q	R	S	T	U	V	W	X
Adr_adresse1	Adr_adresse2	Code_postal	Ville	C_pays	Ll_pays	Siret	Siren	Statut partenaire	C_type_structure
Centre Condorcet	162 av du Dr A. Sch	33608	PESSAC CEDE	100	FRANCE	40328030800012	403280308	0	A
IC2MP - CNRS 7285	4 rue Michel Brunet	86073	POITIERS CED	100	FRANCE	18008901303183	180089013	0	A
Agence comptable	2 SQ LA FAYETTE	49004	ANGERS CEDE	100	FRANCE	38529030900017	385290309	Public	A
LABORATOIRE DE ME	61 AV DU PRESIDEN	94235	CACHAN	100	FRANCE	19940607500010	199406075	0	A
20 AV ALBERT EINSTE	0	69621	VILLEURBANN	100	FRANCE	0	0	0	A
Institut Jean Le Rond	4 PL Jussieu	75230	PARIS CEDEXC	100	FRANCE	19751722000699	197517220	0	A
55 avenue de PARIS	0	78035	VERSAILLES	100	FRANCE	19781944400013	197819444	0	A
Polytech Annecy-Char	0	73376	LE BOURGET-	100	FRANCE	19730858800015	197308588	Public	A
UNIVERSITE LE MANS	AV OLIVIER MESSIA	72017	LE MANS	100	FRANCE	19720916600010	197209166	0	A

Capture de l'ajout des nouveaux blocs d'informations dans notre référentiel

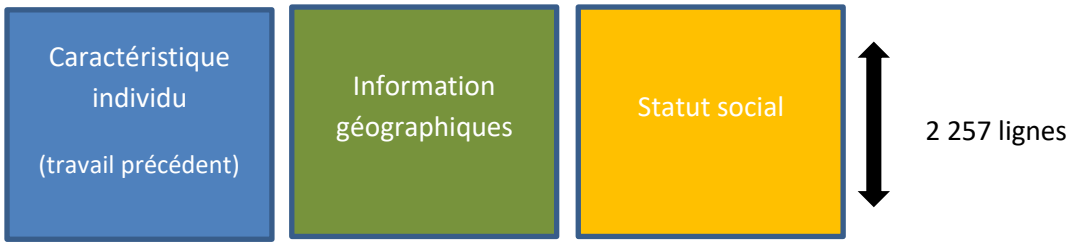

On a également une 3ème table similaire, les individus ont leur caractéristiques géographique, sociale. La différence est que cette table provient d'une extraction moins récente, certaines informations sont donc susceptibles d'avoir changé. On procède à une étape de contrôle qui porte sur n° Siret.

➔ Réalisation d'un code en VBA pour contrôler l'identité des n° Siret dans les 2 tables

```
Option Explicit

Sub differencesSIRET()

Dim indiceLigTable1 As Integer
Dim indiceLigTable2 As Integer
Dim usedLigTable1 As Integer
Dim usedLigTable2 As Integer

' Comptage du nombre de lignes utilisées dans les 2 tables
usedLigTable1 = Application.WorksheetFunction.CountA(Me.Worksheets.Item(1).Columns("A"))
usedLigTable2 = Application.WorksheetFunction.CountA(Me.Worksheets.Item(2).Columns("A"))

' On parcourt les individus dans les 2 tables
    For indiceLigTable1 = 2 To usedLigTable1
        For indiceLigTable2 = 3 To usedLigTable2


        ' On vérifie si à indice égal cela correspond au même persID, et on vérifie le cas de
        ' différents SIRET dans les 2 tables et on le notifie dans une nouvelle colonne
            If Not IsError(Me.Worksheets.Item(1).Cells(indiceLigTable1, 21).Value) Then 'Si dans la 1ere table colonne Siret = #N/A on passe l'individu

                If Me.Worksheets.Item(1).Cells(indiceLigTable1, 1).Value = Me.Worksheets.Item(2).Cells(indiceLigTable2, 1).Value _
                    And Me.Worksheets.Item(1).Cells(indiceLigTable1, 21).Value <> Me.Worksheets.Item(2).Cells(indiceLigTable2, 7).Value Then

                    Me.Worksheets.Item(1).Cells(indiceLigTable1, 25).Value = "ATTENTION"
                    Me.Worksheets.Item(2).Cells(indiceLigTable2, 42).Value = "ATTENTION"


                End If

            End If

        Next
    Next

End Sub
```

Le programme parcourt les 2 tables, lorsqu'il rencontre un **PersId** présent dans les 2 tables il compare la valeur du n° Siret dans leur colonne respective. En cas de différence, il indique pour le **PersId** dans la table '*Cont_Subv_geo_ent*' dans une nouvelle colonne « ATTENTION » pour savoir que l'individu a eu un changement.

RESULTAT

	A	B	C	U	V	W	X	Y
1	PersId du partenaire	Numéro	Nom du partenaire	Siret	Siren	Statut partenaire	C_type_structure	Comparaison SIRET
126	121987	CONT-2021-0327	UNIVERSITE PARIS I	19751717000019	197517170	Public	A	ATTENTION
549	159996	CONT-2009-0203	IPB BORDEAUX	13000635600013	130006356	Public	A	ATTENTION
1390	206279	CONT-2015-0780	L'AFRICAINE D'ARCHITECTURE	82080768300017	820807683	Privé	A	ATTENTION
1602	247398	CONT-2016-0394	POSEIDOM	43345789200019	433457892	Privé	A	ATTENTION
2041	512942	CONT-2021-0327	UNIVERSITE DE PARIS - LIRAES URP4470	13002573700011	130025737	Public	A	ATTENTION

2	PersId du p	Code fournisseur	Numéro du partena	Nom du partenaire	Siret	F
497	159996	INS00096	49166	INP BORDEAUX		
1191	247398	POS00008	92640	POSEIDOM	0	F
1327	206279	LAF00173	63702	L'AFRICAINE D'ARCHITECTURE	0	F
2023	512942	UNI00628	329135	UNIVERSITE DE PARIS - LIRAES URP4470		
2025	121987	UNI00050	40307	UNIVERSITE PARIS I		

5 individus sont indiqués « à risque » dans la table 'Cont_Subv_geo_ent'

Les 5 individus dans la table de comparaison avec un Siret différent

BILAN

A l'issu de ces 2 travaux, on a une table qui compte pour chaque partenaire dont il est précisé son type, son nombre de contrat ou subvention, et enfin ses informations géographiques et sociales s'il s'agit d'une entreprise.

Dans la 2ème partie, l'utilisation d'un script VBA me semblait pertinent même si techniquement je pouvais m'en passer et utiliser les formules de bases d'Excel.

III. 2. Le financement des doctorants

CONTEXTE

Une autre partie du travail fait pendant cette première partie de l'alternance concernait les doctorants et leur financement, ces derniers dépendaient d'une nomenclature qui peut potentiellement contenir des erreurs.

OBJECTIF

Ici le but est de repérer les doctorants pour lesquels il y a une ou des incohérences au niveau des financements.

METHODOLOGIE

Travail sur la table '*Financement_Doctorant_Coherance'* présent sur le serveur. Un onglet correspond à une nomenclature utilisée par l'UPPA, un autre est une extraction des doctorants avec notamment les informations relatives aux financements :

- Origine des fonds
- Code établissement (**Code ED**)

A partir de cette table des doctorants, nous pouvons faire un TCD dans le but de vérifier la cohérence entre le code établissement et l'origine des fonds, en indiquant pour chaque code combien de doctorants sont reliés à ce dernier.

Nombre de FIN1 - Libelle du financement		
FIN1 - Code ED	**FIN1 - Origine des fonds 1**	**Total**
ETAB_C_11_11012	11012_Collectivités / CRNA (Conseil régional de Nouvelle-Aquitaine)_ E2S UPPA	1
A01	A_Sans activité rémunée_Retraité	2
A03	B21_Salarié Education nationale EN (enseignant 2nd degré)	1
	B3_Autre Salarié PRIVE	1
B02	B_Salarié ATER	1
	B1_Salarié ATER	2
B0302	B_Salarié Education nationale EN (enseignant 2nd degré)	3

En -tête du TCD (497 individus au total)

Déjà une première incohérence apparait, les **Code ED** commencent par une lettre et sont rangés dans l'ordre alphabétique, or le premier à sortir est un 'ETAB_...'. Cela est dû au fait qu'il y un espace au début du libellé du code, il s'agit d'une erreur de saisie, et elle est comptée comme une incohérence.

ETAB_C_13_1301	13_i-Site E2S UPPA_ANR	4
	1301_i-Site E2S UPPA_ANR	71
	1704_Partenariats hors CIFRE Financement privé / Total	1

Origine des fonds

Plus loin dans le tableau on trouve **Code ED** 'ETAB_C_13_...' associé à un code d'origine des fonds commençant par '17…' pour ce cas il s'agit d'une incohérence de 2 codes qui ne sont pas censés être associés entre eux selon les règles communiquées.

Pour les 2 incohérences trouvées dans le tableau, cela représente un total de 2 individus, ils sont rentrés dans une nouvelle table *'PB_coherence_FIN1-Code ED'* pour les repérer directement et les corriger.

Ensuite, dans un nouvel onglet *'Libelle_Sans_FIN1-Code ED'* on fait un nouveau TCD cette fois ci dans l'autre sens : on indique pour les codes d'origine des fonds lesquels ne sont pas reliés à un **Code ED**.

Nombre de FIN1 - Libelle du financement		
FIN1 - Origine des fonds 1	FIN1 - Code ED	Total
02_Organismes de recherche / CNRS (Centre national de la recherche scientifique)	(vide)	1
11011_Collectivités / CRNA (Conseil régional de Nouvelle-Aquitaine)_ AAP	(vide)	1
2401_Campus France (gestionnaire de bourses financées) par gouvernement étranger	(vide)	1
A_Sans activité rémunée_Auto-financement	(vide)	3
A_Sans activité rémunée_Pôle emploi	(vide)	4
A_Sans activité rémunée_Retraité	(vide)	2
A1_Auto-financement	(vide)	25
AAP 2022 cotutelles transfrontalières UPPA/UPNA	(vide)	1
KEDGE Business School Bordeaux	(vide)	1
Salaire doctorale	(vide)	1
(vide)	(vide)	1
Total général		41

On indique toujours pour chaque **Code ED** combien d'individus sont présents. Dans ce cas on a 41 doctorants qui ont des fonds de financement sans **Code ED.**

RESULTAT

	A	B	C	D	E	F	G
1	Matricule	Nom	Prenom	Nom d'usa	Prénom d'u	Civilité	Date de na
2	156546		Emmanuel		Emmanuel	Monsieur	30/07/1996
3	142749		Nidal Del Vall		Nidal	Madame	25/04/1996
4	140282		Rehman			Monsieur	05/01/1990
5	154332		Ibrahima			Monsieur	08/10/1996
6	153957		Natalia			Madame	09/03/1991
7	143467		Lamine			Monsieur	18/03/1993
8	147341		Elisabeth		Elisabeth	Madame	24/12/1994
9	143251		Pauline			Madame	21/09/1992
10	141382		Christophe		Christophe	Monsieur	20/01/1967

*10 premiers individus sur les 41 qui n'ont pas de **Code ED***

En cliquant sur le détail du nombre total on a la liste des individus sans **Code ED** avec toutes les autres informations.

Cette table ainsi que la table précédente des 2 individus présentant des incohérences ont été envoyé au service compétent pour modifier les informations erronées, et remplir celles manquantes.

BILAN

Cette tâche ne présentait pas de difficultés particulières si ce n'est l'attention aux détails, notamment le cas avec une erreur de saisie.

III. 3. Les publications des chercheurs de l'UPPA

CONTEXTE

Cette partie sur laquelle j'ai travaillé concerne les publications des chercheurs de l'université. En effet dans une université, le nombre de publications de ses chercheurs peut être un indicateur important.

OBJECTIF

Il faut réussir à qualifier la production scientifique dans les Unités de Recherche.

METHODOLOGIE

Le but de ce travail est en premier lieu de repérer les chercheurs rattachés à l'UPPA de par leurs publications. C'est ce que nous retrouvons dans la table '*ABES_Fourniture_IdRef*', une table composée de chercheurs, dans laquelle nous retrouvons plusieurs informations dont certaines sur leurs publications.

	K	L	M	N	O	P
1	NomPrenom_HAL	Nom formaté	NomPrenom	Nom_LieuDiplome	Note300	Note340
2						
3						
4						
5						
6					ctorat en géophysique - télédétection (La Rochelle, 2008)	Titulaire d'un doctorat en géoph
7						
8					Historien de la littérature espagnole. Professeur de philologie espagnole à l'Université d	
9					Historien de la littérature espagnole. Professeur de philologie espagnole à l'Université d	
10					Historien de la littérature espagnole. Professeur de philologie espagnole à l'Université d	

10 première lignes de la table 'ABES_Fourniture_IdRef'

On retrouve sur cette partie 2 formats différents de nom/prénom et 2 variables **Note300** et **Note340** qui correspondent à l'intitulé du diplôme obtenu ainsi que le lieu d'obtention. Le code couleur en jaune indique que la variable ne provient pas du jeu de données d'origine et qu'elle est ajoutée à la main. Ici pour repérer les doctorants reliés à l'UPPA on fait une jointure sur une table utilisée dans un travail précédent, (localisation par SIRET) celle issue de Aghrum *'DPAAC COCKTAIL GRHUM.INDIVIDU_U'*

	A	B	C	D	E	F	G	H
1	No_indivic	Nom_patr	Prenom	Nom_Prenom	NomPrenom	Nom formate	Pers_id	C_civilite
2	8660		MATTHIEU				113951	M.
3	8660		CYRIL				113952	M.
4	8660		AMADOU				113953	M.
5	8660		NOUR-EL-HC				113954	MLLE
6	8660		VERONIQUE				113955	MLLE
7	8660		FABIEN				113956	M.
8	8661		SEBASTIEN				113957	M.
9	8661		LOIC				113958	M.
10	8661		MELANIE				113959	MLLE

10 premières lignes de 'DPAAC COCKTAIL GRHUM.INDIVIDU_U'

On fait cette jointure avec une **RECHERCHEV** en utilisant le format de nom en colonne M de *ABES_Fourniture_IdRef*', on obtient 24 110 lignes sur 81 804 lignes totales. On parle de lignes ici et pas d'individus car il y a des doublons. Les doublons proviennent du fait que pour un certain nombre d'individus, l'orthographe de leur nom diffère. Pour ceux qui ont un

nom composé, il se peut que pour un même individu il apparaisse plusieurs fois avec une partie du nom manquante.

Pour essayer de récupérer plus d'ID on va créer une nouvelle variable de nom/prénom avec un nouveau format issu d'une fonction python.

```
Entrée [18]: import re
def format_name(name):
    last_comma_first = name.split(", ")
    first_parts = re.split('[.\s-]+', last_comma_first[1])
    first_initials = ' '.join([f.strip()[0].upper() if f.strip() else '' for f in first_parts])
    if len(first_initials) > 0:
        first_initials = ' ' + first_initials
    return last_comma_first[0] + ", " + first_initials
```

Cette fonction sépare le nom en 2 : première partie avant une ',' ou '-' et un espace, la deuxième partie est ce qui vient après. Ensuite dans la seconde partie, la fonction garde la ou les initiales en majuscule en les séparant par un espace.

Ainsi en appliquant cette formule, l'individu :

Clément, Naprous ; Clément, N. ; Clément, N -> Clément, N

Dans la table *'ABES_Fourniture_IdRef'* la colonne **Nom formaté** est l'application de la fonction sur **NomPrenom_HAL.** Maintenant avec ce nouveau format, on peut créer une nouvelle variable **Nom_LieuDiplome** sa formule est la suivante :

=SI(ET(O2<>"";P2<>"");L2&"- "&O2&" "&P2;SI(O2<>"";L2&"- "&O2;SI(P2<>"";L2&"- "&P2;"")))

On fusionne notre nouveau format de nom avec l'intitulé et lieu du diplôme en une seule variable. Avec cette nouvelle variable on peut chercher à récupérer plus d'informations.

N	O	P	Q	R
Nom_LieuDiplome	Note300	Note340	PERSID	halAuthorId
			FAUX	1721817
			FAUX	1337763
			FAUX	1337763
			FAUX	1158073
			FAUX	1578315
			FAUX	11517065
			FAUX	11523396
			FAUX	11522501
			FAUX	11522501

La nouvelle formule pour avoir le PersID est :

=SI(ESTNA(RECHERCHEV(SIERREUR(GAUCHE(N2;CHERCHE("-";N2)-1);"");'DPAAC COCKTAIL GRHUM.INDIVIDU_U'!F:G;2;FAUX));SI(R2=R1;Q1);RECHERCHEV(SIERREUR(GAUCHE(N2;CHERCHE("-";N2)-1);"");'DPAAC COCKTAIL GRHUM.INDIVIDU_U'!F:G;2;FAUX))

On cherche le nom en colonne N dans la table *'DPAAC COCKTAIL GRHUM.INDIVIDU_U'* et on prend également en compte le **halAuthorId.** Il s'agit d'un ID de publication, l'ancienne

jointure récupérait des IDs pour des individus mais parfois malgré un **halAuthorId** similaire l'un avait un ID et pas l'autre, cette nouvelle formule corrige cette situation. Avec cette nouvelle formule on récupère un peu plus d'information avec 27 391 lignes contre 24 110 avant.

Une autre méthode est actuellement en cours, elle se base sur une nouvelle table issue d'une autre extraction. La structure est vaguement similaire à la précédente, avec nom prénom du doctorant, l'unité de recherche à laquelle il rattaché, et différents IDs relatifs aux publications IdHAL, IdORCID et IdRef. A partir de cette extraction, on dérive dans une nouvelle table en filtrant sur les unités de recherche de l'UPPA. Cette nouvelle table a 11 378 lignes et comporte des doublons.

La démarche consiste à créer un TCD pour les 3 types d'IDs de cette sorte :

Nombre de Affiliation			
Nom	Prénom	idHAL	Total
	Ghaya		4
	Christelle		1
	Silvia		2
	Ahmed		8
	Sabri		3
	Sabri		1

Les doublons proviennent du fait qu'un individu peut être relié à plusieurs IDs, de ce fait on fait une nouvelle table où le nombre d'ID est en variable, ID1, ID2. A partir de cette dernière table, on peut faire un TCD dans lequel on pourra filtrer les individus qui ont plusieurs ID, et de ce fait ils apparaissent une seule fois.

Nom	Prénom	idHal1	idHal2
	Laurent		
	Maïder		
	Stéphane		
	Mohamed		
	Sahraoui		
	Mohammed		
	Caroline		

On fait la même chose pour les 2 autres IDs, et lorsqu' on a 3 tables sans doublons on peut les joindre pour avoir 1 ligne = 1 individu avec tous ses IDs possibles.

III. 4. Visualisation de données

Au cours de cette dernière partie, j'ai été chargé de mettre à jour le rapport d'activité de l'université pour l'année 2022. Cette tâche a été très intéressante car elle m'a permis de voir comment les données de l'université étaient utilisées pour piloter son activité. Les parties du rapport sur lesquelles j'ai travaillé concernaient les subventions et les contrats de l'UPPA.

Pour les subventions, j'ai été amené à produire des graphiques permettant de visualiser la répartition des subventions par collège et par unité de recherche. Par exemple, pour le collège STEE, j'ai créé un graphique montrant la répartition des subventions par unité de recherche. Ce graphique a permis de mettre en évidence les unités de recherche qui bénéficiaient du plus grand nombre de subventions et celles qui en bénéficiaient le moins.

Cependant, en travaillant sur ce rapport, j'ai réalisé qu'il était important d'aller au-delà de ces données globales pour apporter une vision plus précise de la répartition des subventions. C'est pourquoi j'ai créé deux nouveaux graphiques montrant pour chaque unité de recherche, la provenance des subventions qu'elle recevait. Ces graphiques ont permis de mieux comprendre comment les subventions étaient réparties entre les différentes unités de recherche et de mettre en évidence celles qui étaient les plus dynamiques dans l'obtention de subventions.

Pour les contrats, j'ai travaillé sur la mise à jour des chiffres pour l'année 2022. Cette tâche a été relativement simple car il s'agissait simplement de mettre à jour les chiffres pour l'année en cours. Cependant, cela m'a permis de mieux comprendre comment les contrats étaient gérés à l'université et comment les données sur les contrats étaient utilisées pour piloter l'activité de l'université. J'ai utilisé les mêmes types de visualisation que pour les subventions ci-dessous.

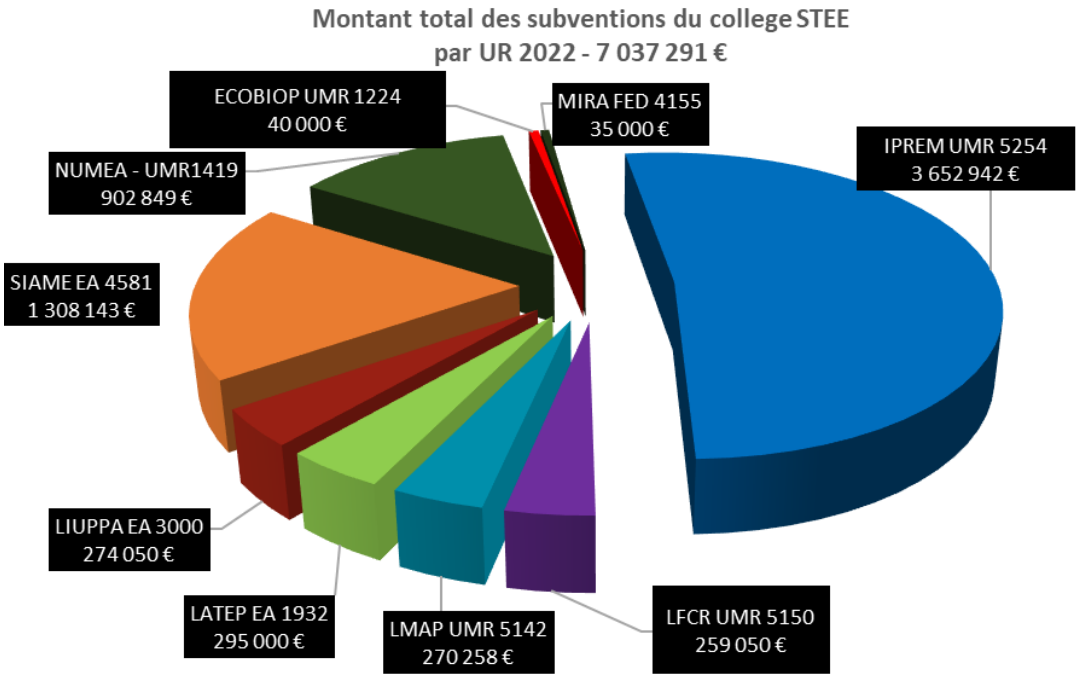

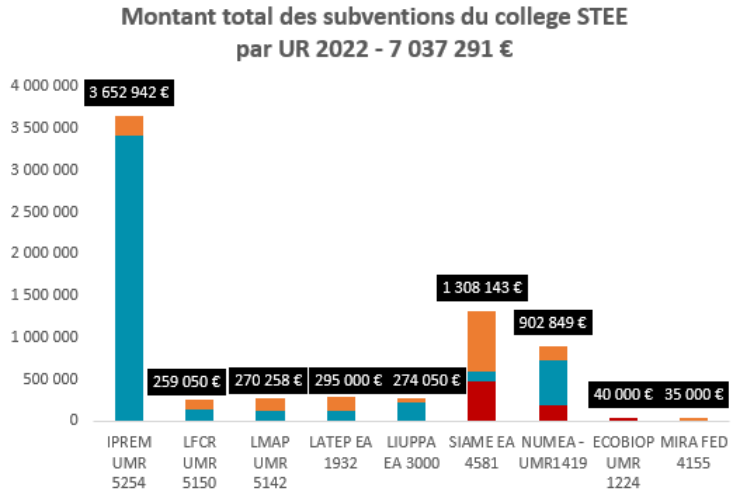

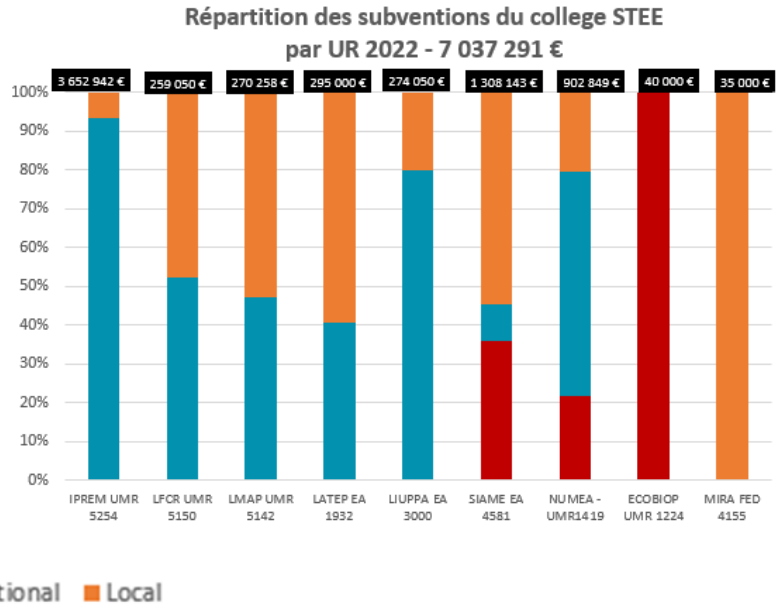

Cette visualisation de données des contrats comme des subventions provient de 2 fichiers excel. Le but final était de rendre ces comptes rendus à 2 collègues du pôle de la DRV travaillant respectivement sur les périmètres contrats et subventions. De ce fait je devais faire en sorte de rendre un livrable le plus lisible possible avec pour chaque graphique le TCD correspondant avec les filtres associés. Ainsi, on garde le côté évolutif pour les graphiques dont les données sources sont adaptables.

IV. Bilan de cette première partie d’alternance

Jusqu’à présent, bien que les tâches réalisées n’étaient pas forcément complexes d’un point de vue technique, la difficulté reposait sur l’appréhension des différentes tables à ma disposition. En effet pour chaque « mini projet » il fallait faire face à des tables dont la structure n’était pas forcément similaire et savoir quelles données utiliser.

Cependant, j’ai vraiment apprécié le fait de travailler sur différents thèmes, et ainsi voir de l’intérieur les problématiques et missions auxquelles peut être confronté une université.

Cela a représenté un défi pour moi, car cela m'a demandé une grande rigueur et une grande attention aux détails. J'ai dû me familiariser avec chaque table de données et être en mesure de comprendre rapidement leur structure et leur contenu.

Cependant, malgré ces difficultés, j'ai vraiment apprécié travailler sur ces différents projets, car ils m'ont permis de découvrir des thèmes très variés. En travaillant sur des sujets comme la gestion financière de l’UPPA à travers les contrats et subventions auprès d’intervenants extérieurs, la publication des chercheurs au sein de l’université, la partie de visualisation de données sur les rapports d’activités. J'ai pu voir de l'intérieur, les problématiques et les missions auxquelles peut être confrontée une université.

Cette expérience m'a donc permis d'acquérir de nouvelles compétences en matière de gestion de données et d'analyse de données. J'ai appris à travailler avec différentes sources de données et à les exploiter pour répondre à des questions spécifiques. J'ai également pu développer mes compétences en matière de communication, car j'ai dû expliquer mes résultats et mes conclusions à mes collègues et à mes supérieurs hiérarchiques.

En somme, cette expérience a été très enrichissante pour moi, car elle m'a permis de découvrir de nouveaux domaines et d'acquérir de nouvelles compétences professionnelles.

V. Seconde partie d’alternance

V. 1.1. Retour sur le référentiel HAL

Depuis la prise en 100% entreprise l’essentiel du travail effectué c’est focalisé sur le référentiel HAL.

CONTEXTE

Qualifier la production scientifique dans les Unités de Recherche.

HAL (Hyper Articles en Ligne) est la source utilisée, il s’agit une plateforme commune d'archive ouverte, qui a été adoptée par les institutions de recherche françaises, les universités et les grandes écoles, suite à un protocole d'accord signé en juin 2006 à l'Académie des sciences. Cette décision résulte d'un processus de concertation et d'accord entre les principaux acteurs de l'enseignement supérieur et de la recherche en France, qui a abouti à la signature de ce protocole. Il a ensuite été suivi par une convention signée en avril 2013, pour renforcer davantage le cadre formel de coopération entre ces institutions autour de l'utilisation de la plateforme HAL.

Lancée en 2001 par le Centre pour la communication scientifique directe (CCSD) du CNRS, HAL est une plateforme numérique consacrée au dépôt et à la diffusion des productions scientifiques de chercheurs, qu'elles soient publiées ou non. Elle accueille aussi les thèses de doctorat, toutes issues des établissements d'enseignement et de recherche, qu'ils soient français ou étrangers, et qu'ils appartiennent au secteur public ou privé. Cette plateforme représente un instrument essentiel pour la visibilité internationale et l'accessibilité de la recherche scientifique française.

La spécificité de HAL réside dans le fait qu'elle offre un accès libre aux données. Tout un chacun peut consulter les documents qui y sont déposés, sans avoir à payer de frais d'abonnement ou de téléchargement. Cependant, il est important de noter que si l'accès aux données est libre, leur utilisation ou leur réutilisation n'est pas nécessairement libre également. Les droits d'utilisation de chaque document sont définis par l'auteur ou l'institution qui a déposé le document, et il est essentiel de respecter ces droits.

En 2023, HAL se positionne comme la plus grande base de données pour la recherche francophone. Elle compte environ 1 100 000 publications, provenant d'institutions et de chercheurs francophones du monde entier. Cela démontre son rôle central et sa contribution significative à la promotion de la recherche scientifique francophone, en facilitant l'accès aux résultats de recherche et en promouvant la collaboration entre chercheurs de diverses disciplines et institutions.

V. 1.2. La bibliométrie et ses objectifs

La bibliométrie est une discipline qui applique des méthodes statistiques et mathématiques pour mesurer et évaluer la production et la diffusion de publications scientifiques. Elle englobe l'utilisation de formules complexes visant à fournir des indices de performance de la recherche pour les individus (chercheurs et chercheuses), les laboratoires, les établissements, les pays, et bien d'autres.

En tant qu'outil, la bibliométrie vise à mesurer non seulement la quantité de production scientifique, mais aussi l'impact de la recherche. L'évaluation de cet impact consiste à analyser les avantages résultant des activités scientifiques et de leurs résultats, qui sont ensuite mis à la disposition de la communauté de chercheurs et chercheuses. Bien que la bibliométrie soit un outil essentiel pour cette évaluation, il existe d'autres méthodes complémentaires pour rendre compte de cet impact, chacune ayant ses propres limites. Par exemple, les altmetrics, qui évaluent l'impact d'une publication sur Internet, sont aujourd'hui reconnus comme des mesures alternatives importantes.

Les indicateurs bibliométriques sont nombreux et leur utilisation est largement répandue dans le milieu de la recherche. Ils sont devenus indispensables et font partie intégrante du fonctionnement des institutions scientifiques. Ils sont utilisés dans différentes situations, notamment :

- Pour soutenir la planification et la gestion stratégique de la recherche ;
- Dans l'attribution de financements pour des programmes de recherche ;
- Dans la sélection de candidats pour des postes de chercheurs ;
- Pour évaluer la performance de la recherche au niveau des universités, comme en témoignent les classements internationaux et l'évaluation annuelle supervisée par le Hcéres (Haut Conseil de l'évaluation de la recherche et de l'enseignement supérieur).

Certains indicateurs sont spécifiquement utilisés pour mesurer l'influence d'une revue scientifique ou d'un livre, en particulier dans les domaines des sciences humaines et sociales. Le facteur d'impact est l'un des indicateurs les plus connus dans ce contexte.

D'autres indicateurs évaluent l'activité scientifique d'un chercheur, d'une chercheuse ou d'un groupe de chercheurs selon différents aspects tels que la production, la collaboration et l'impact. Ils vont des indicateurs basiques, tels que le nombre de citations, à des indicateurs plus élaborés, comme l'indice h, qui prend en compte à la fois le nombre de publications et le nombre de citations reçues. Ces indicateurs permettent de mesurer et de comparer la performance scientifique dans le cadre de la recherche.

V. 1.3. Exploitation des dépôts HAL

OBJECTIF

Le but de ce projet est donc d'élaborer un référentiel qui fait part du nombre de productions au sein de l'UPPA. Il est notamment utile à l'ensemble des collèges qui composent l'université pour des questions de financements qui sont liés au nombre de productions.

METHODOLOGIE

Le travail commence à partir d'une extraction qui était fournie par une responsable du Service d'appui à la recherche au sein du Service Commun de Documentation de l'UPPA (SCD). De cette première requête on obtient la table de départ dans un csv.

La table de départ est *'ExtractionHAL(GL)2018-2023_2023'* et possède 33 935 entrées (publications nationales), les variables sont les suivantes :

- Nom
- Prénom
- Autre nom
- Affiliation
- Affiliation(2)
- Affiliation(3)
- Affiliation(4)
- Affiliation(5)
- Affiliation(6)
- Nom du domaine messagerie
- idHAL
- Id ORCID
- Id idRef
- Id arXiv
- ID Forme-ID Auteur
- Type de document
- Année
- Titre
- Soumis le Projet(s) ANR
- Projet(s) Européens
- Identifiants
- Auteurs

La table retrace les productions, 1 ligne = 1 individu impliqué dans une production. De ce fait, si dans l'historique des données entre 2018 et 2023 un individu était impliqué dans 50 productions alors on aura 50 lignes à son nom. Le but est d'avoir une table finale d'individus sans doublons qui qualifie l'individu avec son nombre de production(s).

V. 1.4. Qualification des individus de l'UPPA

Les chiffres que nous voulons sortir et pouvoir analyser sont focalisés sur les individus appartenant à l'UPPA. Pour ce faire, on travaille sur les Affiliations. Il s'agit de l'unité de recherche auquel l'individu est rattaché au moment d'une publication. Ainsi on peut repérer les individus rattachés à des unités de l'UPPA.

Pour ce faire, on crée notre variable **NOMP** dans la *'ExtractionHAL(GL)_modif'* qui est une copie de notre extraction de base pour ne pas l'écraser et travailler dessus directement. A partir de *'ExtractionHAL(GL)_modif'* on crée un TCD pour chaque **NOMP** / **Affiliation** dont on importe le tableau en sortie dans une table distincte pour chaque affiliation nommée *'auteur aff[i]'*.

On a donc les tables de *'auteur aff1'* à *'auteur aff6'* qui suivent le schéma suivant :

NOMP	Affiliation
X_n	- Y_1 - Y_2 - ... - Y_n

Si dans chaque table un auteur est affilié à plusieurs unités alors des doublons sont créés, le but est d'arriver à la forme suivante :

NOMP	Affiliation1	Affiliation2	Affiliation...	$Affiliation_n$
- X_1 - X_2 - ... - X_n				

Avoir une ligne pour un individu, et toutes les possibilités d'affiliation en tant que variable.

La première méthode utilisée était avec un script R.

```
#---------- PACKAGES

library(readxl)
library(dplyr)
library(stringr)
library(tidyr)
library(writexl)

#----------

# LinÃ©arisation tables Affiliation

data <- read_excel(path = './DATA/Extraction_HAL_2.xlsx', sheet = 'auteur aff1')

data_clean <- distinct(data, NOM_P, Affiliation)

data_grouped <- data_clean %>%
  group_by(NOM_P) %>%
  summarise(Affiliations = paste(Affiliation, collapse = "!")) %>%
  separate_rows(Affiliations, sep = "\\!\\") %>%
  group_by(NOM_P) %>%
  summarise(Affiliations_sep = paste(Affiliations, collapse = "!"))

data_grouped$Affiliations_sep <- sapply(data_grouped$Affiliations_sep, paste, collapse = "!")

writexl::write_xlsx(data_grouped, './RESULTAT/data_clean.xlsx')
```

Ce code est utilisé sur chaque table *'auteur aff[i]',* les valeurs sont groupées par rapport au **NOMP** pour supprimer les doublons et les affectations différentes sont concaténées en étant séparées par un séparateur, ici ' !'. La table résultat est ensuite exportée dans un répertoire du projet.

Cette approche a une limite, en effet pour chaque export il faut manuellement préciser le séparateur pour que les colonnes soient créées avant de tout assembler dans une table finale.

L'objectif est donc de trouver un moyen de supprimer ces interventions manuelles. Pour ce faire, j'ai opté pour une utilisation de python, pour automatiser un certain nombre d'actions agissant directement sur un fichier Excel. Ce procédé permet d'anticiper des évolutions à venir du projet, d'éviter de multiplier les langages utilisés et de centraliser l'ensemble du processus sur un seul outil.

```
Entrée [1]: # Linéarisation de chaque table 'auteur aff[i]' créée au préalable (TCD de chaque NOMP et Aff depuis 'ExtractionHAL(GL)_modif')
# Ces tables qui sont linéarisées sont ensuite fusionnées dans une nouvelle feuille 'table combinaison auteurs'

import pandas as pd
from openpyxl import load_workbook

# Linéarisation des tables d'affiliation
sheets = ['auteur aff1', 'auteur aff2', 'auteur aff3', 'auteur aff4', 'auteur aff5', 'auteur aff6']

# Liste pour stocker les DataFrames des fichiers "data_affY"
data_frames = []

for i, sheet in enumerate(sheets, start=1):
    # Lecture du fichier Excel
    data = pd.read_excel('C:/Users/cnaprous/PROJ_BIBLIO/HAL3/DATA/ExtractionHAL.xlsx', sheet_name=sheet)

    # Nettoyage et regroupement des données
    column_name = f'Affiliation{i}'
    data_clean = data.drop_duplicates(subset=['NOMP', column_name])
    data_clean[column_name] = data_clean[column_name].astype(str)
    data_grouped = data_clean.groupby('NOMP')[column_name].apply(lambda x: '!'.join(x)).reset_index(name=f'Affiliation{i}')

    # Diviser la colonne en plusieurs colonnes
    split_columns = data_grouped[f'Affiliation{i}'].str.split('!', expand=True)
    num_columns = split_columns.shape[1]
    data_grouped = pd.concat([data_grouped, split_columns], axis=1)

    # Renommer les colonnes autres que 'NOMP'
    new_columns = ['NOMP']
    for j in range(2, num_columns + 3):
        new_columns.append(f'Affiliation{i}_bis{j}')
    if len(new_columns) < 11:
        new_columns += [f'Affiliation{i}_bis{j}' for j in range(num_columns + 3, 12)]
    data_grouped.columns = new_columns[:num_columns+2]

    column_to_split = new_columns[1]
    split_columns = data_grouped[column_to_split].str.split('!', expand=True)
    data_grouped = pd.concat([data_grouped, split_columns], axis=1)
    data_grouped.drop(column_to_split, axis=1, inplace=True)

    # Ajouter le DataFrame à la liste
    data_frames.append(data_grouped)

    # Écriture des données dans un fichier Excel
    output_file = f'C:/Users/cnaprous/PROJ_BIBLIO/HAL3/RESULTAT/data_aff{i}.xlsx'
    data_grouped.to_excel(output_file, index=False)

# Fusion des DataFrames en fonction de la colonne 'NOMP'
combined_data = data_frames[0]
suffixes = ['']  # List to store suffixes for each merged DataFrame

for df_index in range(1, len(data_frames)):
    suffix = f'_{df_index}'
    suffixes.append(suffix)
    combined_data = pd.merge(combined_data, data_frames[df_index], on='NOMP', how='outer', suffixes=('', suffix))

# Création de la feuille "table combinaison auteurs"
combined_sheet_name = 'table combinaison auteurs'

# Écriture des données dans le fichier Excel
output_file = 'C:/Users/cnaprous/PROJ_BIBLIO/HAL3/DATA/ExtractionHAL.xlsx'
with pd.ExcelWriter(output_file, mode='a', engine='openpyxl') as writer:
    writer.book = load_workbook(output_file)
    writer.sheets = dict((ws.title, ws) for ws in writer.book.worksheets)
    if combined_sheet_name in writer.sheets:
        writer.book.remove(writer.sheets[combined_sheet_name])
    combined_data.to_excel(writer, sheet_name=combined_sheet_name, index=False)
```

Le code python fait la même chose que le script R précédent, il se base sur les tables *'auteur aff[i]'* et effectue un Goup by sur la variable **NOMP,** et les valeurs sont séparées et placées

dans les colonnes automatiquement. Le résultat est automatiquement placé dans une nouvelle table '*table combinaison auteurs*'.

	A	I	J	K	
1	NOMP	Affiliation1_bis2	Affiliation1_bis3	Affiliation1_bis4	Affil
2		MSU (1755 - ...)			
3		ICMMO (1998 - 2019)			
4		NAVIER UMR 8205 (2020 - ...)			
5		LIREM (2021 - ...)			
6		SCU			
7		Universidade de Coimbra [Coimbra]			
8		Department of Clinical Genetics			
9		DTU Aqua, National Institute of Aquatic Resources			
10		SINTEF Digital			
11		Sechenov First Moscow State Medical University			
12		IFPEN			
13		CEH (1985 - 2022)			
14		ISM			
15		CRAJ (1995 - 2020)	UPPA (1970 - ...)		
16		IPREM (2006 - ...)			
17		ENSACF			
18		SIAME (2011 - ...)			
19		Center for Electrochemical E	Electron Microscopy for Mat	EMAT, University of Antwerp	Skoltech
20		Center for Electrochemical E	Skoltech		
21		LTDS (1992 - ...)			
22		PSI			
23		CATT (1991 - 2020)	IRMAPE (2007 - ...)	TREE (2021 - ...)	
24		ESC PAU			
25		MRM			
26		Department of Mathematics	LIUPPA (1999 - ...)		
27		IPREM (2006 - ...)			
28		CBI (2014 - ...)	ESPCI Paris (1882 - ...)		
29		Université Ain Shams			

Feuil1 | auteur aff1 | auteur aff2 | auteur aff3 | auteur aff4 | auteur aff5 | auteur aff6 | **table combinaison auteurs**

➔ 11 145 entrées

Une fois cette table obtenue, en ayant pour chaque individu toutes les possibilités d'affiliation, il est possible de déterminer s'il s'agit potentiellement d'un membre de l'UPPA. Pour ce faire, j'ai créé un nouveau programme qui consiste à parcourir pour chaque individu de la table '*table combinaison auteurs*' l'ensemble des colonnes d'affiliation. Dès lors qu'on rencontre une affiliation présente dans la liste des unités de l'UPPA, alors l'individu est noté comme VRAI dans une nouvelle colonne **Potentiel UPPA** et on passe à l'individu suivant, sinon il est noté FAUX.

```
Entrée [2]: # Les colonnes de 'table combinaison auteurs' correspondent à toutes les possibilités d'affiliation pour les individus.
# Cette boucle vérifie pour chaque individu si une de ses affiliations se trouve dans la 'liste_valeur', si c'est le cas alors
# il est noté 'Potentiel_UPPA'
import pandas as pd
from openpyxl import load_workbook

filename = "C:/Users/cnaprous/PROJ_BIBLIO/HAL3/DATA/ExtractionHAL.xlsx"
df = pd.read_excel(filename, sheet_name='table combinaison auteurs')

liste_valeurs = ["ALTER (2018 - ...)", "C2MA (2012 - 2019)", "CATT (1991 - 2020)", "CDRE (1999 - ...)",
                 "CRAJ (1995 - 2020)", "CRPHLL (1999 - 2017)", "DICE (2013 - ...)", "DMEX (2011 - ...)",
                 "ECOBIOP (2000 - 2019)", "ECOBIOP (2020 - ...)", "EXPERICE (2005 - ...)", "IFTJ (2021 - ...)",
                 "IKER (1999 - ...)", "IPREM (2003 - 2005)", "IPREM (2006 - ...)", "IRAA (1957 - ...)",
                 "ITEM (1999 - ...)", "ITEM (2002 - ...)", "LATEP (1995 - ...)", "LFCR (2003 - ...)",
                 "LIREM (2021 - ...)", "LITEM (2020 - ...)", "LIUPPA (1999 - ...)", "LLCAA (1995 - 2017)",
                 "LMAP (2005 - ...)", "MEPS (2009 - ...)", "Passages (2016 - 2021)", "Passages (2021 - ...)",
                 "PDP (1995 - 2020)", "PhLAM (1998 - ...)", "SATIE-SIAME (... - 2019)", "SET (1981 - 2015)",
                 "SIAME (2011 - ...)", "TREE (2021 - ...)", "NuMéA (2016 - 2019)", "Magique 3D",
                 "MAGIQUE-3D (2007 - ...)", "CREG (... - 2020)", "MAKUTU (2021 - ...)", "NuMéA (2020 - ...)",
                 "UPPA (1970 - ...)"]
# Création de la colonne "Potentiel UPPA"
df.insert(1, "Potentiel UPPA", False)

# Vérification des colonnes 2 à 89 pour chaque individu
for index, row in df.iterrows():
    for col in df.columns[2:90]:
        if row[col] in liste_valeurs:
            df.at[index, "Potentiel UPPA"] = True
            break

# Écriture des données dans le fichier Excel
book = load_workbook(filename)
writer = pd.ExcelWriter(filename, engine='openpyxl')
writer.book = book
writer.sheets = dict((ws.title, ws) for ws in book.worksheets)
df.to_excel(writer, sheet_name='table combinaison auteurs', index=False)
# Sauvegarder les changements
writer.save()
writer.close()
book.close()
```

Maintenant que nous avons notre nouvelle variable pour déterminer si un individu appartient potentiellement à l'UPPA, nous pouvons essayer de récupérer le maximum de **PersID** pour ces individus.

Pour ce faire, on effectue une jointure entre notre table '*table combinaison auteurs*' et *'GHRUM_INDIVIDUS_230614'.* Cette seconde table est un référentiel des membres de l'UPPA dans lequel on peut récupérer un certain nombre d'éléments, dont les **PersID.**

Avant de procéder à la jointure entre nos 2 tables, il faut effectuer un premier processus de nettoyage des données pour essayer de récupérer un maximum de **PersID** en automatique. Effectivement notre jointure va se faire sur le **NOMP** '*table combinaison auteurs*' et une nouvelle variable **NOMP** créée automatiquement dans *'GHRUM_INDIVIDUS_230614'.* Sauf qu'en se basant sur des tests réalisés en amont, il y a un certain nombre d'individus pour lesquels il y a des formats de nom différents entres les 2 tables : par exemple une même personne, dans une table son nom est à particule avec un ' de ' ou ' du ' et qui n'est pas le cas dans la seconde table.

Pour corriger ce problème on applique sur la table *'GHRUM_INDIVIDUS_230614'* un script également utilisé précédemment sur '*table combinaison auteurs*'.

```
Entrée [6]: # Création des variables NOMP et NOMP2 dans 'GHRUM_INDIVIDUS_230614' et nettoyage de ces dernières pour correspondre à
# NOMP de 'ExtractionHAL(GL)_modif'


import pandas as pd
import re
from unidecode import unidecode
from openpyxl import load_workbook

# Charger le classeur Excel
filename = "C:/Users/cnaprous/PROJ_BIBLIO/HAL3/DATA/ExtractionHAL.xlsx"
sheet_name = 'GHRUM_INDIVIDUS_230614'

# Charger la feuille Excel dans un DataFrame pandas
df = pd.read_excel(filename, sheet_name=sheet_name)

# Créer les deux nouvelles variables NOMP et NOMP2
df['NOMP'] = df['NOM_PATRONYMIQUE'].str.upper() + ', ' + df['PRENOM']
df['NOMP2'] = df['NOM_USUEL'].str.upper() + ', ' + df['PRENOM']

# Appliquer les transformations sur les variables NOMP et NOMP2
replacements = {
    r'(?i)\bDU\b': '',
    r'(?i)\bDE\b': '',
    r'(?i)\bLE\b': '',
    r'(?i)\bLA\b': '',
    r'(?<!\s)-(?!\s)': ' ',
    r' -': ' ',
    r'- ': ' '
}
df['NOMP'] = df['NOMP'].replace(replacements, regex=True)
df['NOMP2'] = df['NOMP2'].replace(replacements, regex=True)

# Supprimer les espaces en premier caractère
df['NOMP'] = df['NOMP'].str.lstrip()
df['NOMP2'] = df['NOMP2'].str.lstrip()
# Appliquer d'autres transformations sur les variables NOMP et NOMP2 (ex: suppression des espaces en trop)
df['NOMP'] = df['NOMP'].str.replace(r'\s+', ' ')
df['NOMP2'] = df['NOMP2'].str.replace(r'\s+', ' ')

# Spécifier l'ordre des colonnes
column_order = list(df.columns[:5]) + ['NOMP', 'NOMP2'] + list(df.columns[5:])

# Créer un nouveau DataFrame avec l'ordre de colonnes spécifié
df_new = df[column_order]

# Ouvrir le classeur Excel en utilisant openpyxl
book = load_workbook(filename)

# Sélectionner la feuille à modifier
writer = pd.ExcelWriter(filename, engine='openpyxl')
writer.book = book

# Écrire les données modifiées dans la feuille sélectionnée
writer.sheets = dict((ws.title, ws) for ws in book.worksheets)
df_new.to_excel(writer, sheet_name=sheet_name, index=False)

# Sauvegarder les changements
writer.save()

# Fermer le writer et le book
writer.close()
book.close()
```

Ce script se base alors sur *'GHRUM_INDIVIDUS_230614'*, il créé dans un premier temps 2 formats de **NOMP** en utilisant les 2 formes de noms utilisés concernant certains individus. Il applique ensuite les changements sur les formats de ces 2 variables.

On peut donc effectuer notre jointure dans ‘*table combinaison auteurs*’.

	A	D	E	F	G	H
1	**NOMP**	**NOMP2**	**PersID1**	**PersID2**	**PersID_comb**	**Potentiel UPPA**
5			192159	192159	192159	VRAI
6			#N/A	#N/A	#N/A	FAUX
7			#N/A	#N/A	#N/A	FAUX
8			#N/A	#N/A	#N/A	FAUX
9			#N/A	#N/A	#N/A	FAUX
10			#N/A	#N/A	#N/A	FAUX
11			#N/A	#N/A	#N/A	FAUX
12			#N/A	#N/A	#N/A	FAUX
13			#N/A	#N/A	#N/A	FAUX
14			175791	175791	175791	FAUX
15			110829	110829	110829	VRAI
16			512780	512780	512780	VRAI

Les formules en E et F sont respectivement :

=SIERREUR(RECHERCHEV(A2;auteurAffilies_UPPA220112!C:J;8;FAUX);INDEX(GHRUM_INDIVIDUS_230614!B:B;EQUIV('table combinaison auteurs'!A2;GHRUM_INDIVIDUS_230614!F:F;0)))

=SIERREUR(RECHERCHEV(D2;auteurAffilies_UPPA220112!D:J;7;FAUX);INDEX(GHRUM_INDIVIDUS_230614!B:B;EQUIV('table combinaison auteurs'!A2;GHRUM_INDIVIDUS_230614!F:F;0)))

En colonne G pour avoir le **PersID** final la formule est :

=SI(OU(ESTERREUR(E2);ESTERREUR(F2));SI(ESTERREUR(E2);F2;SI(ESTERREUR(F2);E2));SI(E2=F2;E2))

Elle permet de récupérer un ID lorsqu’on un #N/A dans une des 2 colonnes précédentes.

Une fois ces étapes effectuées on peut filtrer dans ‘*table combinaison auteurs*’ notre variable **Potentiel UPPA** sur les individus marqués en VRAI.

Ainsi sur nos 11 145 entrées totales, on a 2 232 entrées qui concernent des membres actuels ou anciens de l’UPPA. On peut copier ces valeurs dans une nouvelle table nommée *‘UPPA’.*

Désormais, dans cette nouvelle table on se charge, de retirer les doublons présents et parmi les individus qui n’ont toujours pas de **PersID** essayer de les trouver. Ces tâches complètent l’utilisation des script précédents, et se font manuellement.

On arrive finalement à 2 038 individus distincts qui sont marqués comme appartenant à l’UPPA.

V. 1.5. Caractéristiques des produisant

Maintenant que nous avons notre table de nos 2 038 individus membres de l'UPPA, nous pouvons passer à l'étape ayant pour but d'évaluer la production de ces derniers et leur qualification. Pour ce faire, dans un premier temps on ajoute dans la table *'UPPA'* des informations RH (grades, permanents/non permanent, personnel de recherche). Cet ajout se fait avec une table nommées *'BO_31122022'* qui existe déjà et qui correspond à la qualité du personnel de l'UPPA.

G	H	I	J	K	L	M	N	O	P
PersID	Potentiel UPP	Accronyme chai	Etab d'origine	e (personnel rech	Role_SANGRIA	tation principale	ffectation laborat	Corps	Grade
0	VRAI		#N/A	#N/A	#N/A	#N/A	#N/A	#N/A	#N/A
169796	VRAI		Université de Pau et	MEMBRE NON PERM	MEMBRE NON PERM	Collège Sciences et T	IPREM Institut des sc	IGR RF	IGR 2C RF
508850	VRAI		#N/A	#N/A	#N/A	#N/A	#N/A	#N/A	#N/A
255364	VRAI		#N/A	#N/A	#N/A	#N/A	#N/A	#N/A	#N/A
0	VRAI		#N/A	#N/A	#N/A	#N/A	#N/A	#N/A	#N/A
247300	VRAI		Université de Pau et	DOCTORANT	DOCTORANT	Collège Sciences et T	LATEP Laboratoire d	CT CONTRA	CT DOCT
140048	VRAI		#N/A	#N/A	#N/A	#N/A	#N/A	#N/A	#N/A
0	VRAI		#N/A	#N/A	#N/A	#N/A	#N/A	#N/A	#N/A
255506	VRAI		#N/A	#N/A	#N/A	#N/A	#N/A	#N/A	#N/A
113134	VRAI		Université de Pau et	0	MEMBRE PERMANE	Collège Etudes Euro	IFTJ Institut fédérati	MCF	MCF EX

La jointure entre les 2 tables se fait avec le **PersID** qu'on a obtenu précédemment. Ces nouvelles variables vont nous aider à déterminer la qualité de nos individus.

Maintenant que nous avons toutes les informations nécessaires, nous pouvons les rapatrier sur notre table de base *'ExtractionHAL(GL)_modif'.* Ainsi, sur nos 33 935 entrées (publications nationales) nous avons les informations qui vont permettre de faire le décompte des publications par un personnel de l'UPPA.

D	Z	AB	AC	AD	AE	AF	AG	AH
NOMP	Potentiel UPPA	Etab d'origir	Rôle (personnel recherch	Role_SANG	ion principa	ctation labo	Corps	Grade
	VRAI	#N/A	#N/A	#N/A	#N/A	#N/A	#N/A	#N/A
	VRAI	#N/A	#N/A	#N/A	#N/A	#N/A	#N/A	#N/A
	FAUX	#N/A	#N/A	#N/A	#N/A	#N/A	#N/A	#N/A
	FAUX	#N/A	#N/A	#N/A	#N/A	#N/A	#N/A	#N/A
	VRAI	#N/A	#N/A	#N/A	#N/A	#N/A	#N/A	#N/A
	FAUX	#N/A	#N/A	#N/A	#N/A	#N/A	#N/A	#N/A
	VRAI	#N/A	#N/A	#N/A	#N/A	#N/A	#N/A	#N/A
	VRAI	#N/A	#N/A	#N/A	#N/A	#N/A	#N/A	#N/A
	VRAI	Université de Pa	MEMBRE PERMANENT	MEMBRE PER	Collège Scienc	LIREM Labora	MCF	MCF CN

A partir de ces derniers ajouts nous pouvons créer la dernière table '*Qualification publiants*'. Cette dernière est issue d'un TCD qui permet de faire un décompte des publications en mettant en colonne le nombre de publication(s) par année.

La finalité de ces créations de tables et de travail sur ce référentiel est de fournir un livrable aux différentes unités de recherche de l'UPPA, et en l'occurrence le périmètre sur lequel elles souhaitent observer les publications est celui de 2019 à 2022. De ce fait, on crée cette nouvelle variable dans la nouvelle table.

A	B	L	M	N	O	P	Q	R	S
PersID	NOMP	2018	2019	2020	2021	2022	2023	Total géné	NB publi 2019-2022
0			1	2				3	3
0		1	1	3	5	7	3	20	16
0			1					1	1
0			1					1	1
0		1	1	1				3	2
0		1	1					2	1
0		4	3	3		1		11	7
0			1					1	1
0			1					1	1
0		2	1					3	1
0		5	7	3	11	4		30	25
0		7	8	7	10	2		34	27
0		1						1	0
0		7	8	6	8	4	2	35	26
0		6	5	1		1	1	14	7

Désormais, nous avons le nombre de publications pour chaque individu ainsi que certaines informations tel que le grade de ces derniers par exemple. Ainsi nous pouvons calculer de nouvelles variables pour déterminer la qualité des publiant.

A	B	J	S	T	U	V	W
PersId	NOMP	Corps	NB publi 2019-2022	Publiant 2019-2022 PERMANENT UPPA	Test publiant	typologie publiant	Test permanen
30492		#N/A	4	#N/A	Non publiant	#N/A	NON PERMANENT
30696		#N/A	1	#N/A	Non publiant	#N/A	NON PERMANENT
31055		MCF	2	ec / c	Publiant	ec / c	PERMANENT
31055		MCF	11	ec / c	Publiant	ec / c	PERMANENT
31386		#N/A	1	#N/A	Non publiant	#N/A	NON PERMANENT
31733		#N/A	1	#N/A	Non publiant	#N/A	NON PERMANENT
32074		CT CONTRA	3	#N/A	Non publiant	#N/A	NON PERMANENT
32370		IR-R CNRS	1	FAUX	Non publiant	ec / c	NON PERMANENT

La formule de ces 3 dernières variables sont respectivement :

1. Dans notre table '*Qualification publiants',* si le **Corps** de l'individu est dans la nomenclature et que son nombre de publication entre 2019 et 2022 est au moins supérieur à celui indiqué dans la nomenclature, alors l'individu est noté comme 'Publiant' sinon 'Non publiant'.

=SIERREUR(SI(ET(ESTTEXTE(RECHERCHEV(J2;'nomenclature Permanents'!B:B;1;FAUX));S2>=RECHERCHEV(J2;'nomenclature Permanents'!B:D;3;FAUX));"Publiant";"Non publiant");"Non publiant")

2. La seconde formule se base également sur le Corps de l'individu et renvoie la typologie du membre (enseignant chercheur/autres biats/autre enseignant).

=RECHERCHEV(J2;'nomenclature Permanents'!B:C;2;FAUX)

3. Enfin, la dernière formule indique si l'individu est un permanent ou non.

=SI(G2="MEMBRE PERMANENT";"PERMANENT";"NON PERMANENT")

La première et seconde formule se servent de la table de nomenclature suivante :

	A	B	C	D	E
1	Rôle (personnel recherche)	Corps	typologie pub	Nombre min publi 4ans	
2	MEMBRE PERMANENT	ADJENES	autres biats	1	
3	MEMBRE PERMANENT	AI-R CNRS	autres biats	1	
4	MEMBRE PERMANENT	ASIRF	autres biats	1	
5	MEMBRE PERMANENT	Ass ing form	autres biats	1	
6	MEMBRE PERMANENT	CHARG DE RI	ec / c	1	
7	MEMBRE PERMANENT	CR	ec / c	1	
8	MEMBRE PERMANENT	TECH RF(NES	autres biats	1	
9	MEMBRE PERMANENT	DIR. CNRS	ec / c	1	
10	MEMBRE PERMANENT	DR	ec / c	1	
11	MEMBRE PERMANENT	IE-R CNRS	ec / c	1	
12	MEMBRE PERMANENT	IGE	autres enseig	1	
13	MEMBRE PERMANENT	IGR RF	ec / c	1	
14	MEMBRE PERMANENT	Ing études	autres enseig	1	
15	MEMBRE PERMANENT	Ing recherche	ec / c	2	
16	MEMBRE PERMANENT	INGENIEUR M	ec / c	2	
17	MEMBRE PERMANENT	IR-R CNRS	ec / c	2	
18	MEMBRE PERMANENT	MAIT.ASSI.	ec / c	2	
19	MEMBRE PERMANENT	MCF	ec / c	2	
20	MEMBRE PERMANENT	PR	ec / c	2	
21	MEMBRE PERMANENT	PR ASMT	ec / c	2	
22	MEMBRE PERMANENT	SAENES 10	autres biats	2	
23	MEMBRE PERMANENT	Tech form re	autres biats	2	
24	MEMBRE PERMANENT	TECH RECH C	autres biats	2	
25	MEMBRE PERMANENT	ATRF	autres biats	1	
26	MEMBRE PERMANENT	AGT.CONT	autres biats	1	
27	MEMBRE PERMANENT	ATERM	autres biats	1	
28	MEMBRE PERMANENT	MCF ASMT	ec / c	2	
29	MEMBRE PERMANENT	PRAG	autres enseig	1	
30	MEMBRE PERMANENT	SANS CORPS	autres biats	1	
31	MEMBRE PERMANENT	AAE	autres biats	1	

A ce stade le référentiel est terminé, mais on peut apporter une critique sur l'ensemble du processus pour le créer : bien que les différents scripts python font gagner du temps dès le début, on se retrouve rapidement avec un certain nombre de tables intermédiaires dans lesquelles on est amené à faire des allers-retours pour ajouter des informations. C'est pourquoi la partie suivante a pour but de montrer le changement qui a été pris dans la création de ce référentiel.

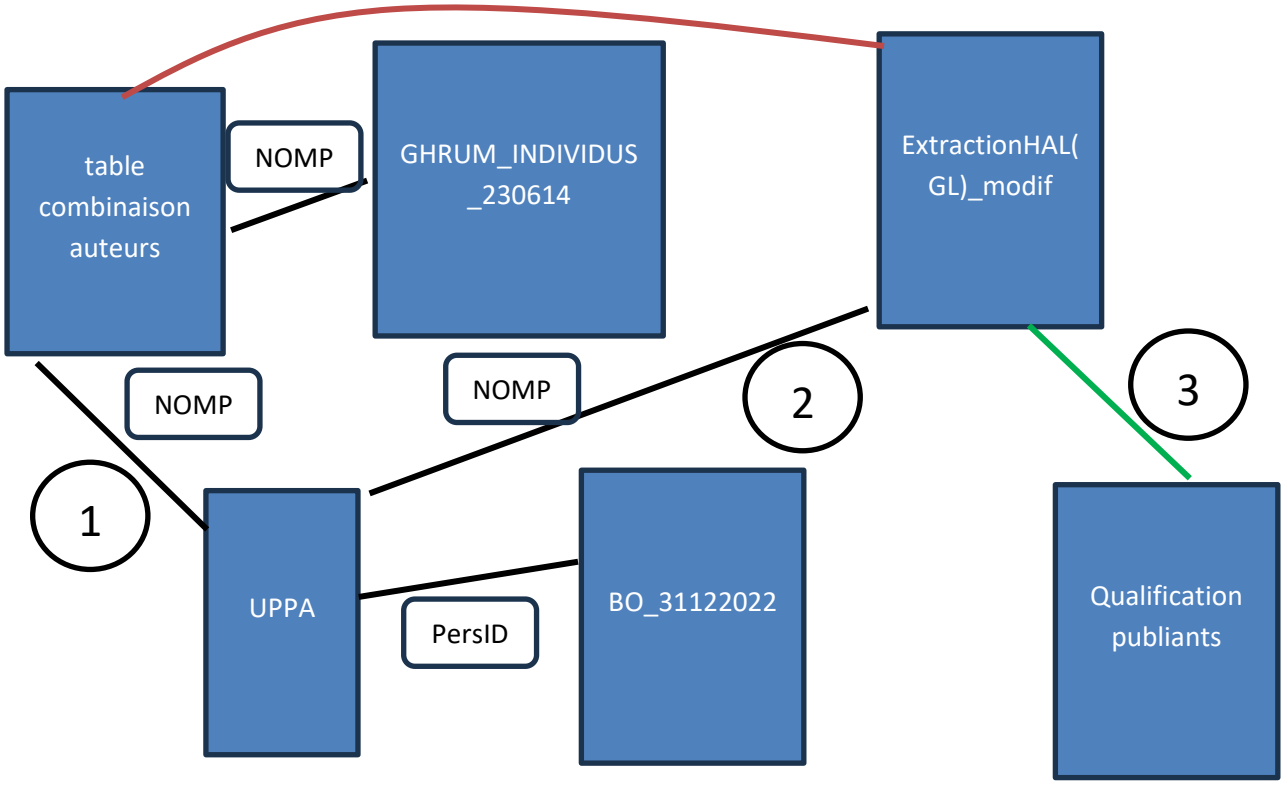

V. 2. Changement de méthode

Comme premier changement majeur, on détermine si un individu est potentiellement un membre de l'UPPA directement dans la table d'extraction de 33 935 entrées. Plus besoin de passer par des tables intermédiaires pour chaque affiliation comme dans la méthode précédente.

Pour se faire on utilise le script suivant :

```
Entrée [30]: #creer une variable  combinant 2 variables ___Attention Nom "FAUX" (= vrai nom et nom "FALSE")
             df['NOMP']=df['Nom']+', '+df['Prénom']

Entrée [31]: liste_valeurs = ["ALTER", "CRPHLL", "LCAA", "EFM","CRAJ", "ISCJ","PDP", "IFTJ", "PASSAGES", "Passages", "SET", "CATT", "TREE", "
                 "IE2IA", "ITEM", "LAM", "IRAA","EXPERICE", "IKER",  "CDRE", "CREG", "LIREM",
                 "ECOBIOP", "NuMéA", "NUMEA", "LFCR", "LMAP", "Magique 3D", "MAGIQUE-3D", "MAKUTU", "SIAME","LATEP", "LaTEP",
                 "LIUPPA", "IPREM", "C2MA", "DMEX", "MIRA", "IPRA","UPPA"]
             regex='\s*'+'\s|\s*'.join(liste_valeurs)+'\s'
             regex

Out[31]: '\\s*ALTER\\s|\\s*CRPHLL\\s|\\s*LCAA\\s|\\s*EFM\\s|\\s*CRAJ\\s|\\s*ISCJ\\s|\\s*PDP\\s|\\s*IFTJ\\s|\\s*PASSAGES\\s|\\s*Passages
         \\s|\\s*SET\\s|\\s*CATT\\s|\\s*TREE\\s|\\s*MEPS\\s|\\s*DICE\\s|\\s*IE2IA\\s|\\s*ITEM\\s|\\s*LAM\\s|\\s*IRAA\\s|\\s*EXPERICE\\s|
         \\s*IKER\\s|\\s*CDRE\\s|\\s*CREG\\s|\\s*LIREM\\s|\\s*ECOBIOP\\s|\\s*NuMéA\\s|\\s*NUMEA\\s|\\s*LFCR\\s|\\s*LMAP\\s|\\s*Magique 3
         D\\s|\\s*MAGIQUE-3D\\s|\\s*MAKUTU\\s|\\s*SIAME\\s|\\s*LATEP\\s|\\s*LaTEP\\s|\\s*LIUPPA\\s|\\s*IPREM\\s|\\s*C2MA\\s|\\s*DMEX\\s|
         \\s*MIRA\\s|\\s*IPRA\\s|\\s*UPPA\\s'

Entrée [32]: df['Affi']=df['Affiliation'].astype('str')+' '+df['Affiliation(2)'].astype('str')+' ' \
                 +df['Affiliation(3)'].astype('str')+' '+df['Affiliation(4)'].astype('str')+' ' \
                 +df['Affiliation(5)'].astype('str')+' '+df['Affiliation(6)'].astype('str')
             df['UPPA auteur'] = df['Affi'].str.contains(regex, regex=True)
             df[df['UPPA auteur']]
```

La variable est ainsi créée dans la table de base.

Y	Z	AA
NOMP	Affi	UPPA aute
	LAM PDP (1995 - 2020) UPPA (1	VRAI
	Passages (2016 - 2021) nan nan	VRAI
	LIEU (1992 - ...) nan nan nan na	FAUX
	CERTOP (1994 - ...) nan nan nan	FAUX
	Passages (2016 - 2021) nan nan	VRAI
	LIEU (1992 - ...) nan nan nan na	FAUX
	ACTé (2017 - 2020) nan nan na	FAUX
	CRAJ (1995 - 2020) nan nan nan	VRAI
	Larefi (... - 2021) Groupement c	VRAI

Le repérage et la suppression des doublons se fait également sur cette même table. La méthode utilisée est un nouveau script python qui utilise la distance de Levenshtein.

```
Entrée [14]: #Make similarity correspondance between tabA and tabB
tabA = dfHAL['ODE_AliasModifié'] # left table that will be kept
tabA = tabA.dropna()
tabB = dfGR[['NOMP','NOMU','PERS_ID']] # right table that provides new info. Join is made by similarity on first column
tabB = tabB.dropna(subset='NOMP')
cutoff = 3

lst_indA = list(tabA.index.to_numpy())
lst_valA = list(tabA.to_numpy())
lst_endA = len(lst_indA)
lst_indB = list(tabB.index.to_numpy())
lst_valB = list(tabB['NOMP'].to_numpy())
lst_valB1 = list(tabB['NOMU'].to_numpy())
lst_valB2 = list(tabB['PERS_ID'].to_numpy())
lst_endB = len(lst_indB)

res = {'SourceInd':[],'SourceTxt':[],'AliasInd':[],'AliasTxt':[],'Ratio':[], 'PERS_ID':[], 'Col':[]}

for i in tqdm(range(lst_endA)):
    search_str = lst_valA[i]
    scoresP = [LS.ratio(search_str,lst_valB[j]) for j in range(lst_endB)]
    scoresU = [LS.ratio(search_str,lst_valB1[j]) for j in range(lst_endB)]
    best_scoreP = max(scoresP)
    best_score_indP = scoresP.index(best_scoreP)
    best_scoreU = max(scoresU)
    best_score_indU = scoresU.index(best_scoreU)

    if best_scoreU > 0.8 or best_scoreP > 0.8:
        if best_scoreU > best_scoreP:
            res['SourceInd'].append(lst_indA[i])
            res['SourceTxt'].append(search_str)
            res['AliasInd'].append(lst_indB[best_score_indU])
            res['AliasTxt'].append(lst_valB1[best_score_indU])
            res['Ratio'].append(best_scoreU)
            res['PERS_ID'].append(lst_valB2[best_score_indU])
            res['Col'].append('NOMU')
        else:
            res['SourceInd'].append(lst_indA[i])
            res['SourceTxt'].append(search_str)
            res['AliasInd'].append(lst_indB[best_score_indP])
            res['AliasTxt'].append(lst_valB[best_score_indP])
            res['Ratio'].append(best_scoreP)
            res['PERS_ID'].append(lst_valB2[best_score_indP])
            res['Col'].append('NOMP')
```

Levenshtein est une méthode qui permet de calculer des distances entres des chaines de caractères. Ainsi, en exécutant ce script, on se retrouve avec de nouvelles variables qui indiquent une distance et un ratio de ressemblance. On se base donc sur cette méthode pour apporter les modifications et pour retirer les doublons.

Y	Z	AA	AB	AC	AD	AE
NOMP	Affi	UPPA autei	Alias	Alias_ind	Alias_dist	Alias_ratio
	LRCS (2012 - ...) RS2E (2022 - ..	FAUX		308.0	3.0	0.9090909090
	LRCS (2012 - ...) RS2E (2022 - ..	FAUX		309.0	1.0	0.9230769230
	LRCS (2012 - ...) RS2E (2022 - ..	FAUX		312.0	1.0	0.9444444444
	ISTerre (2016 - 2019) nan nan n	FAUX		324.0	3.0	0.8235294117
	GeoRessources (2013 - ...) CRE	FAUX		403.0	3.0	0.8275862068
	CRPG (1995 - ...) GeoRessource	FAUX		404.0	3.0	0.8125
	UPV/EHU (1980 - ...) nan nan n	FAUX		511.0	1.0	0.9583333333
	LRCS (2012 - ...) RS2E (2011 - 2(	FAUX		516.0	1.0	0.9230769230
	RS2E (2011 - 2021) Collège de F	FAUX		745.0	2.0	0.9
	MPS (2004 - ...) Institut für Astr	FAUX		784.0	3.0	0.8275862068
	PHENIX nan nan nan nan nan	FAUX		786.0	2.0	0.8

Ici les données de **NOMP** n'ont pas été nettoyés au préalable, donc souvent les différences pour un même individu proviennent de caractères pas toujours présents, comme un '.' ou '-' par exemple.

Lorsque le travail sur les doublons est terminé, alors on peut recréer la table *'Qualification publiants'* de la même façon que la méthode précédente en y ajoutant les mêmes variables avec les mêmes formules.

	A	Q	R	S	T
1	ODE_AlliasModifié	NB publi 2019-202	Test publian	typologie publiant	Test permanence
2		1	Non publiant	#N/A	NON PERMANENT
3		1	Non publiant	#N/A	NON PERMANENT
4		1	Non publiant	#N/A	NON PERMANENT
5		0	Non publiant	#N/A	NON PERMANENT
6		1	Non publiant	#N/A	NON PERMANENT
7		1	Non publiant	#N/A	NON PERMANENT
8		1	Non publiant	#N/A	NON PERMANENT
9		1	Non publiant	#N/A	NON PERMANENT
10		2	Publiant	ec / c	PERMANENT
11		1	Non publiant	#N/A	NON PERMANENT
12		0	Non publiant	#N/A	NON PERMANENT
13		17	Publiant	ec / c	PERMANENT

Maintenant que nous avons toutes les données pour la production finale, on peut rapatrier ces variables dans notre table de personnels '*BO_31122022'* de 1 942 individus.

AR	AS	AT	AU	AW
Test permanence	Test publiant	Typologie publiant	Production	NB publi 2019-2022
PERMANENT	Publiant	ec / c	Produisant	8
PERMANENT	Publiant	ec / c	Produisant	17
#N/A	#N/A	autres enseignants /	Non produisant	#N/A
PERMANENT	#N/A	ec / c	Non produisant	#N/A
#N/A	#N/A	autres enseignants /	Non produisant	#N/A
PERMANENT	Publiant	ec / c	Produisant	54
NON PERMANENT	#N/A	#N/A	Non produisant	#N/A
#N/A	#N/A	autres biats	Non produisant	#N/A
PERMANENT	Publiant	ec / c	Produisant	19
PERMANENT	Publiant	ec / c	Produisant	5
NON PERMANENT	Non publiant	#N/A	Non produisant	2
#N/A	#N/A	autres biats	Non publiant	#N/A
PERMANENT	Publiant	ec / c	Publiant	13

RESULTAT

A partir de cette table nous pouvons faire le TCD qui correspond au livrable final. L'intérêt du TCD est que, une fois dans la main d'une unité de recherche, elle peut directement voir le détail de ses valeurs en cliquant sur ses données respectives.

Étab. Origine	Université de Pau et des Pays de l'Adou										
Nombre de Pers Id	**Étiquettes de colonnes**										
	PERMANENT					**NON PERMANENT**					
Étiquettes de lignes	**ec / c**	**autres enseignants / prag**	**p**	**autres biats**	**Total PERMAN**	**ec / c**	**autres enseignants / prag**	**p**	**autres biats**	**#N/A**	**Total NON PERMAN**	**Total géné**
2EI	**36**		**2**	**38**	**6**		**7**	**6**		**19**	**57**
CDRE Centre de documentation et de recherches européennes	11		1	12	2		2	6		10	22
IKER Centre de recherche sur la langue et les textes basques	2			2							2
LIREM Laboratoire de Recherche en Management	23		1	24	4		5			9	33
SSH	**144**	**5**	**8**	**157**	**11**	**1**	**16**	**52**		**80**	**237**
ALTER Arts/Langages: Transitions & Relations	46	2	2	50	1		3	7		11	61
DICE-IE2IA Droits international, comparé et européen	6		1	7			1	5		6	13
EXPERICE Expérience, ressources culturelles, éducation	2			2							2
IFTJ Institut fédératif de recherches sur les transitions juridiques	20		1	21	4			2		6	27
IRAA Institut de recherche sur l'architecture antique	3			3				1		1	4
ITEM Identités, territoires, expressions, mobilités	14	1	1	16	1	1	2	10		14	30
MEPS Mouvement, équilibre, performance et santé	12			12			2	1		3	15
TREE Transitions énergétiques et environnementales	41	2	3	46	5		8	26		39	85
STEE	**226**	**13**	**20**	**259**	**50**	**4**	**58**	**174**		**286**	**545**
DMEX Développement de méthodologies expérimentales	1			1							1
ECOBIOP Ecologie comportementale et biologie des populations de poissons	5			5	1		1	5		7	12
IPRA Institut Pluridisciplinaire de Recherche Appliquée	3	1	1	5	1		1	4		6	11
IPREM Institut des sciences analytiques et de physico-chimie pour l'environnement et les matéria	63	8	11	82	26	3	17	79		125	207
LATEP Laboratoire de thermique, énergétique et procédés	23		1	24	3		4	13		20	44
LFCR Laboratoire des fluides complexes et leurs réservoirs	30	2	3	35	6		12	28		46	81
LIUPPA Laboratoire d'informatique de l'UPPA	28		1	29	2	1	9	8		20	49
LMAP Laboratoire de mathématiques et de leurs applications de Pau	43	2	3	48			7	21		28	76
NUMEA Nutrition, Métabolisme, Aquaculture	5			5	1			5		6	11
SIAME Laboratoire des sciences pour l'ingénieur appliquées à la mécanique et au génie électriq	25			25	10		7	11		28	53
Total général	**406**	**18**	**30**	**454**	**67**	**5**	**81**	**232**		**385**	**839**

BILAN

Ce travail s'est basé sur plusieurs méthodes au fil du temps. Malgré le fait qu'il n'est pas entièrement automatique, il est quand même beaucoup plus efficace que la première version de ce projet.

VI. Conclusion

Cette année professionnelle a été extrêmement enrichissante et diversifiée, me permettant d'explorer différentes facettes du domaine de la data. Au fil de mes expériences, j'ai eu l'opportunité de plonger dans plusieurs phases clés du processus de gestion et d'exploitation des données, ce qui m'a permis d'acquérir une perspective approfondie.

Dans la première partie de mon expérience en alternance, j'ai concentré mes efforts sur la fiabilisation des données. Mon rôle consistait principalement à transformer des référentiels en informations exploitables. Cette étape, bien que peut-être moins complexe sur le plan technique en termes de manipulation, a souligné l'importance cruciale d'avoir une vision claire et détaillée du système d'information sur lequel j'intervenais. Cette phase m'a permis de mieux comprendre comment les données sous-jacentes forment le socle sur lequel repose toute analyse ultérieure.

La suite de mon parcours m'a conduit vers le domaine de la visualisation des données. Cette étape m'a particulièrement marqué, car elle a mis en lumière la valeur que peut apporter la visualisation pour répondre à des besoins concrets au sein de l'entreprise. J'ai eu l'occasion de traduire des données complexes en graphiques et visualisations claires, ce qui a facilité la prise de décision pour le personnel non technique.

Toutefois, la partie qui a véritablement captivé mon intérêt a été l'automatisation des procédés à l'aide de Python. Cette phase s'est déployée sur plusieurs mois, me permettant de suivre l'évolution des projets au fil du temps. J'ai pris plaisir à constater comment des tâches qui étaient auparavant manuelles et chronophages ont pu être rationalisées et simplifiées grâce à des scripts automatisés. Cette approche m'a permis de répondre à des besoins spécifiques de manière efficiente, tout en réduisant les erreurs humaines et en gagnant en efficacité opérationnelle. En parallèle, j'ai eu l'occasion d'approfondir mes compétences techniques en utilisant de nouvelles bibliothèques Python (essentiellement Pandas), élargissant ainsi mon éventail de compétences dans ce langage que j'avais déjà étudié en formation.

En rétrospective, cette année professionnelle a été une véritable aventure à travers les différentes étapes du traitement des données. Chacune de ces phases m'a apporté des enseignements précieux sur la manière dont les données sont collectées, transformées, visualisées et exploitées pour prendre des décisions éclairées. Cette expérience m'a permis de consolider mes compétences techniques, tout en développant ma capacité à collaborer au sein d'une équipe et à apporter des solutions concrètes aux défis rencontrés.